Tarea 3: Métodos No Lineales

Juan Pablo Castillo
Álvaro Rojas

1. El Viejo XOR: Métodos No-lineales para Problemas No-lineales

Contexto

En esta sección se tiene el objetivo de experimentar con algunos modelos no-lineales sobre un problema de juguete, el cual es bastante famoso en la historia del aprendizaje automático, este es el problema XOR. Se trata de un problema de clasificación linealmente inseparable. En este problema se utilizará distintos modelos no-lineales para analizar su efectividad en clasificar las clases en este problema.

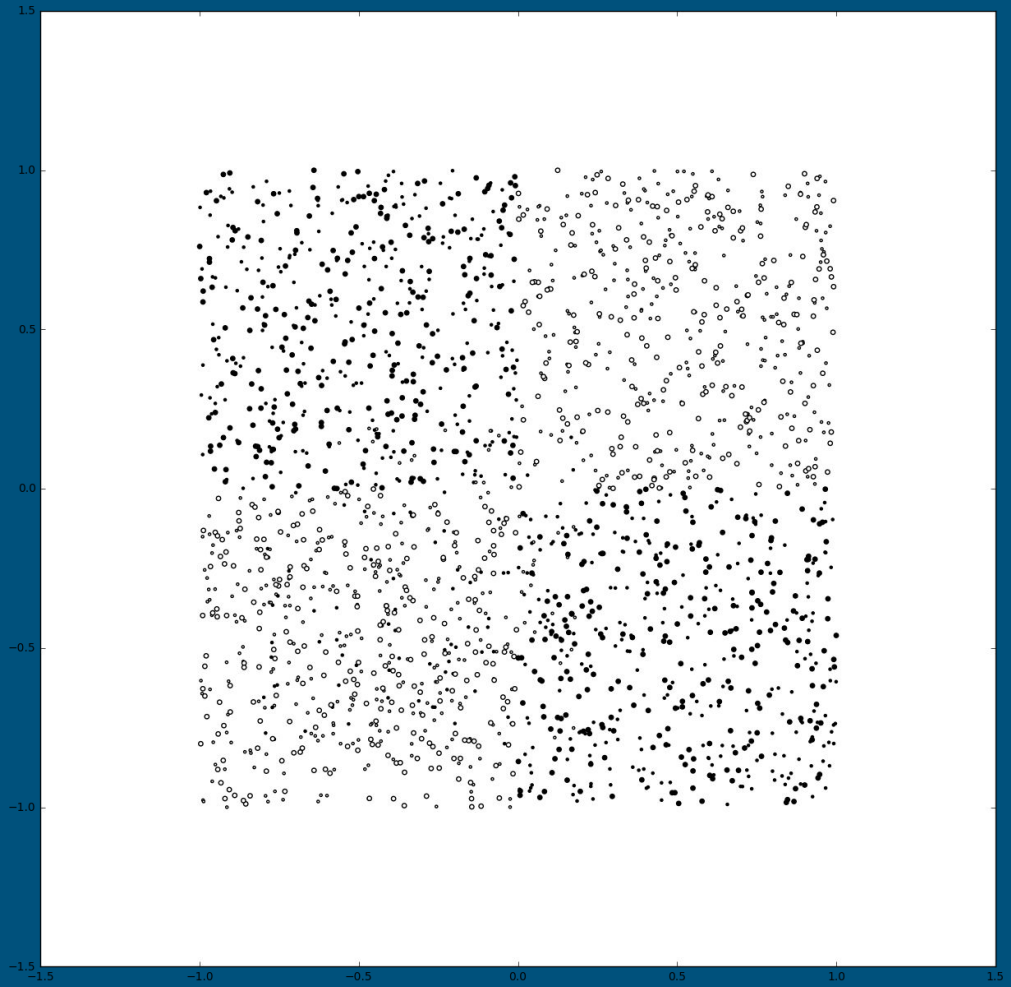
1.5
1.0
0.5
0.0
−0.5
−1.0
−1.5
−1.5
−1.0
−0.5
0.0
0.5
1.0
1.5

Contexto

- Una clase se encuentra en el cuadrante 1 y 3, mientras que la otra clase se encuentra en el cuadrante 2 y 4.

- Es similar al concepto de un "or exclusivo", donde se tiene un valor 1 sólo cuando x e y son distintos. Pero si son iguales, se tendrá un valor 0.

Clasificación con una SVM lineal

```
Mejor parámetro de regularización C: 0.01
Mejor Accuracy de Test: 0.471000
Training Accuracy SVM Lineal: 0.517273
Test Accuracy SVM Lineal: 0.471000
Detailed Analysis Testing Results ...
             precision    recall  f1-score   support

         -1       0.46      0.47      0.46       489
         +1       0.48      0.48      0.48       511

avg / total       0.47      0.47      0.47      1000
```

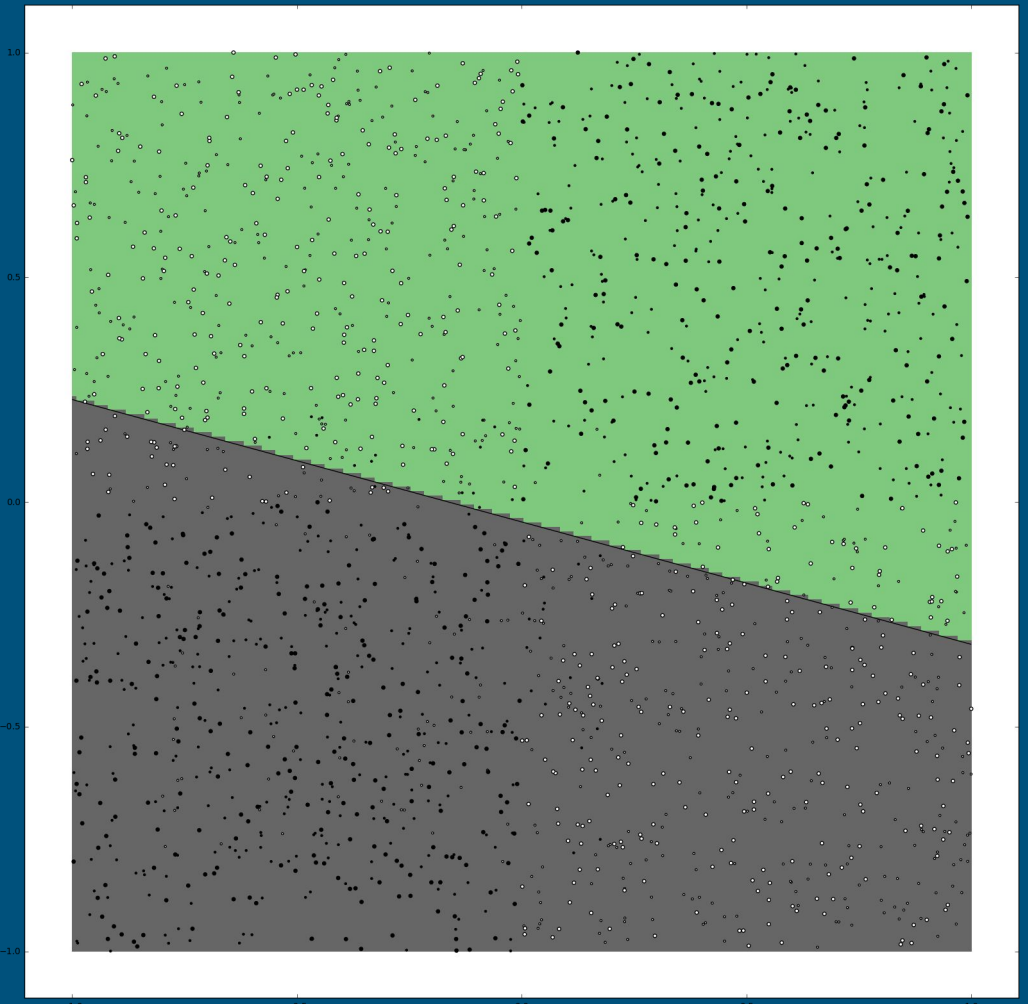
1.0
0.5
0.0
−0.5
−1.0
−1.0
−0.5
0.0
0.5
1.0

Clasificación con SVM no-lineales (rbf)

```
Mejor parámetro de regularización C: 8
Mejor Accuracy de Test: 0.972000
Training Accuracy SVM con kernel rbf: 0.902727
Test Accuracy SVM con kernel rbf: 0.972000
Detailed Analysis Testing Results ...
             precision    recall  f1-score   support

         -1       0.99      0.95      0.97       489
         +1       0.95      0.99      0.97       511

avg / total       0.97      0.97      0.97      1000
```

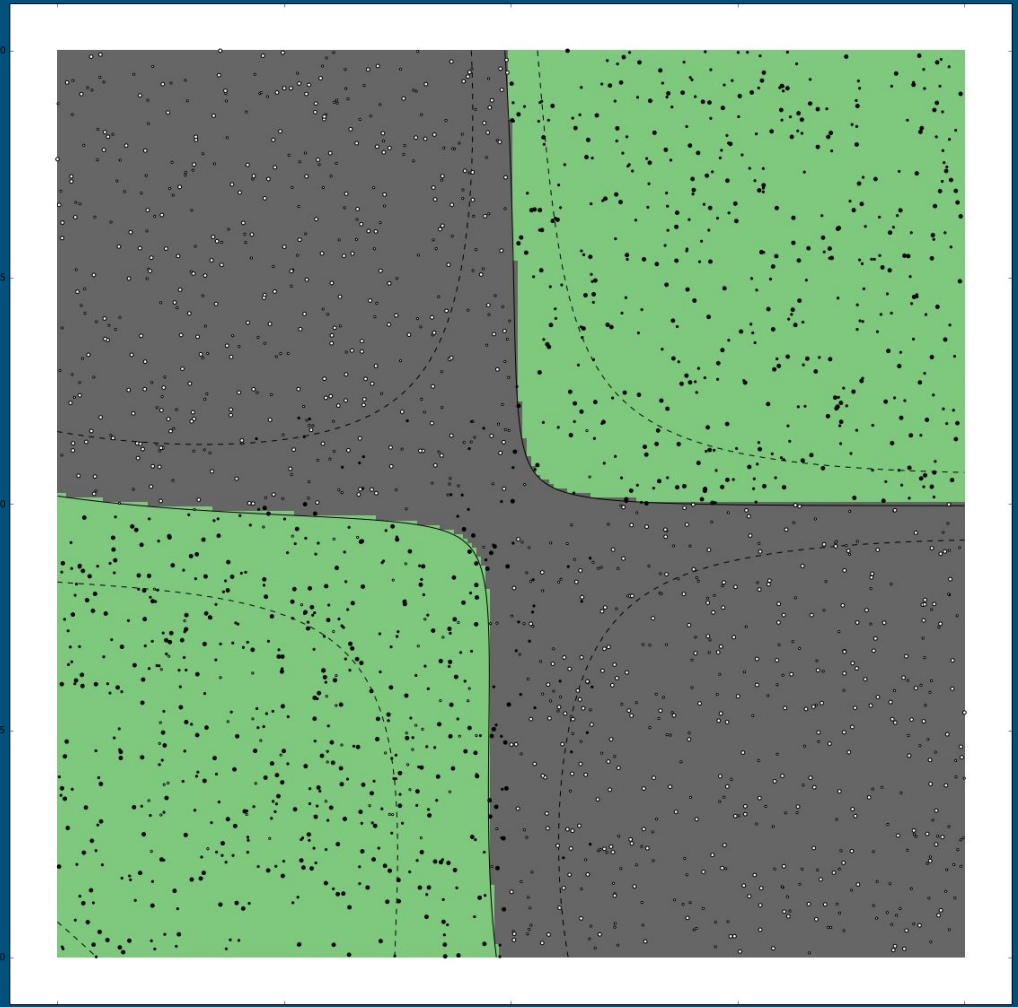
1.0
0.5
0.0
−0.5
−1.0
−1.0
−0.5
0.0
0.5
1.0

Clasificación con SVM no-lineales (polynomial)

```
Mejor parámetro de regularización C: 8
Mejor Accuracy de Test: 0.955000
Training Accuracy SVM con kernel Polinomial: 0.887273
Test Accuracy SVM con kernel Polinomial: 0.955000
Detailed Analysis Testing Results ...
             precision    recall  f1-score   support

         -1       0.99      0.92      0.95       489
         +1       0.93      0.99      0.96       511

avg / total       0.96      0.95      0.95      1000
```

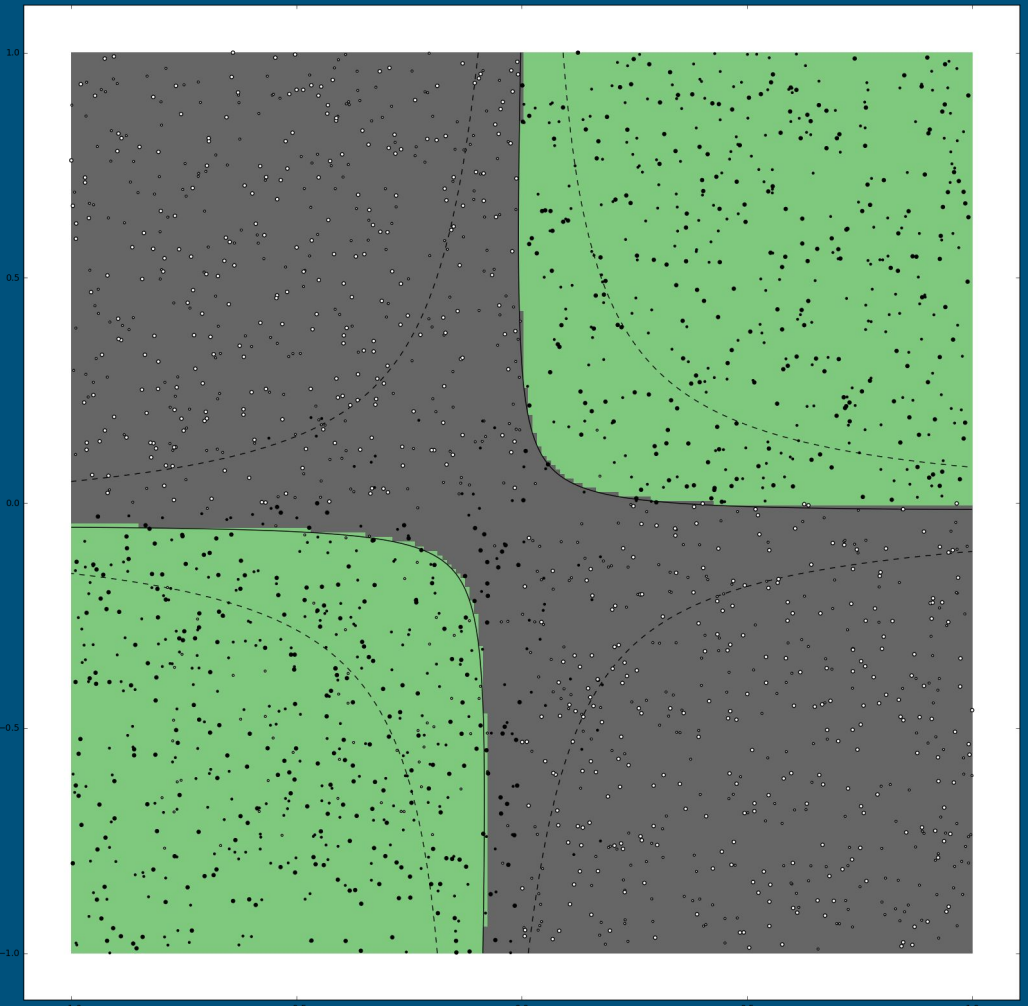
1.0
0.5
0.0
−0.5
−1.0
−1.0
−0.5
0.0
0.5
1.0

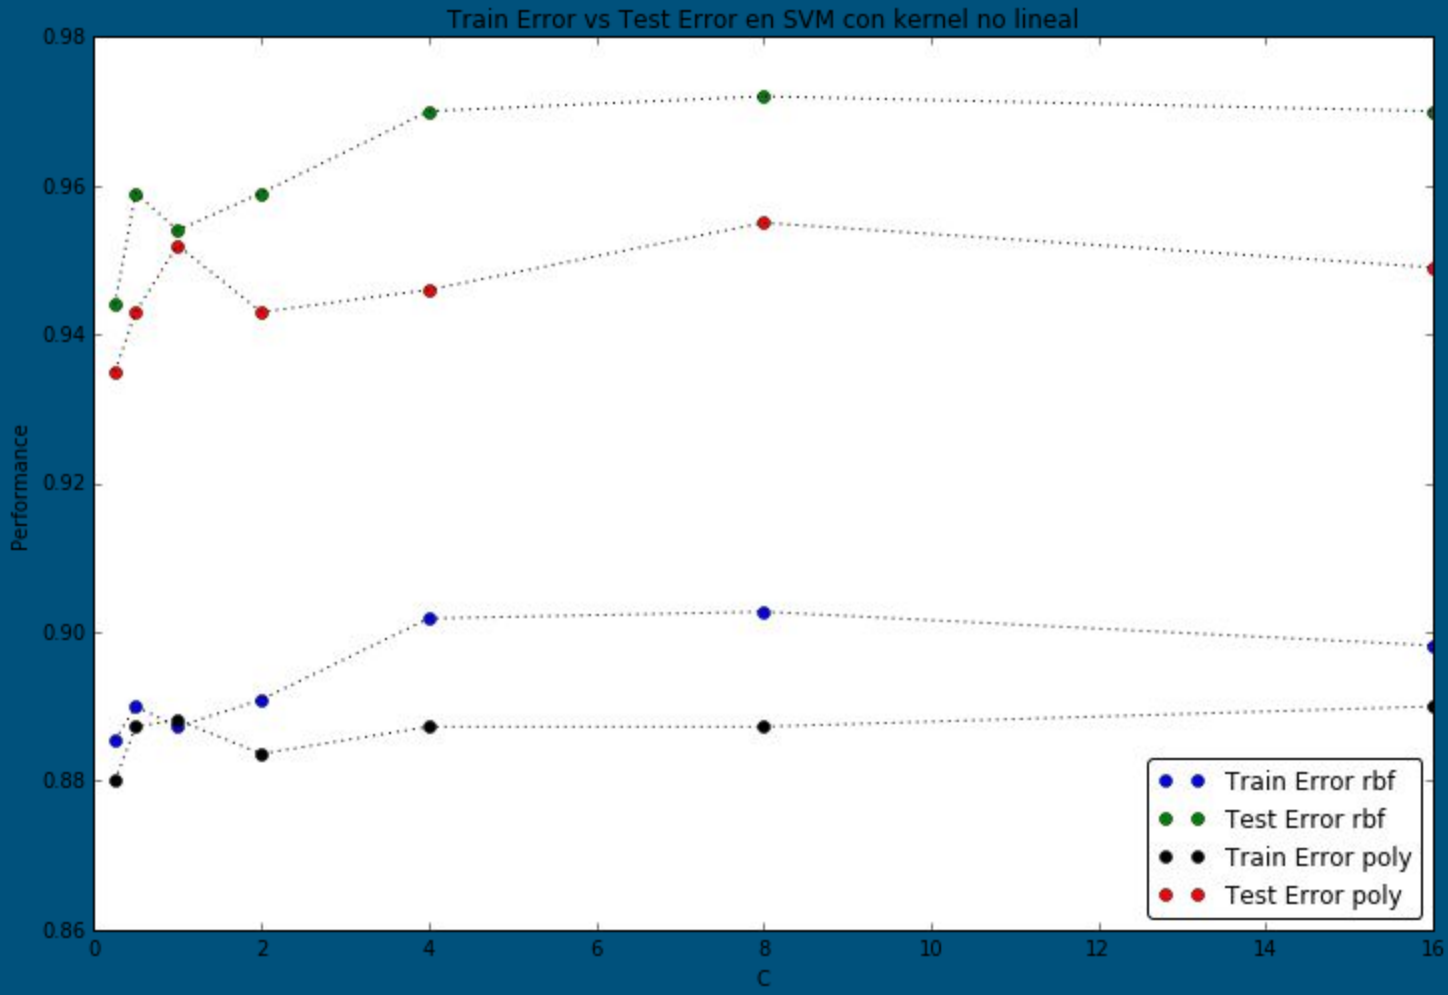
Train Error vs Test Error en SVM con kernel no lineal
Performance
C
0.98
0.96
0.94
0.92
0.90
0.88
0.86
0
2
4
6
8
10
12
14
16
Train Error rbf
Test Error rbf
Train Error poly
Test Error poly

Clasificación con red neuronal artificial de 1 sola neurona

```
Entrenando la red neuronal de 1 neurona...
 928/1000 [==========================>...] - ETA: 0s
Test Accuracy = 0.553000
```

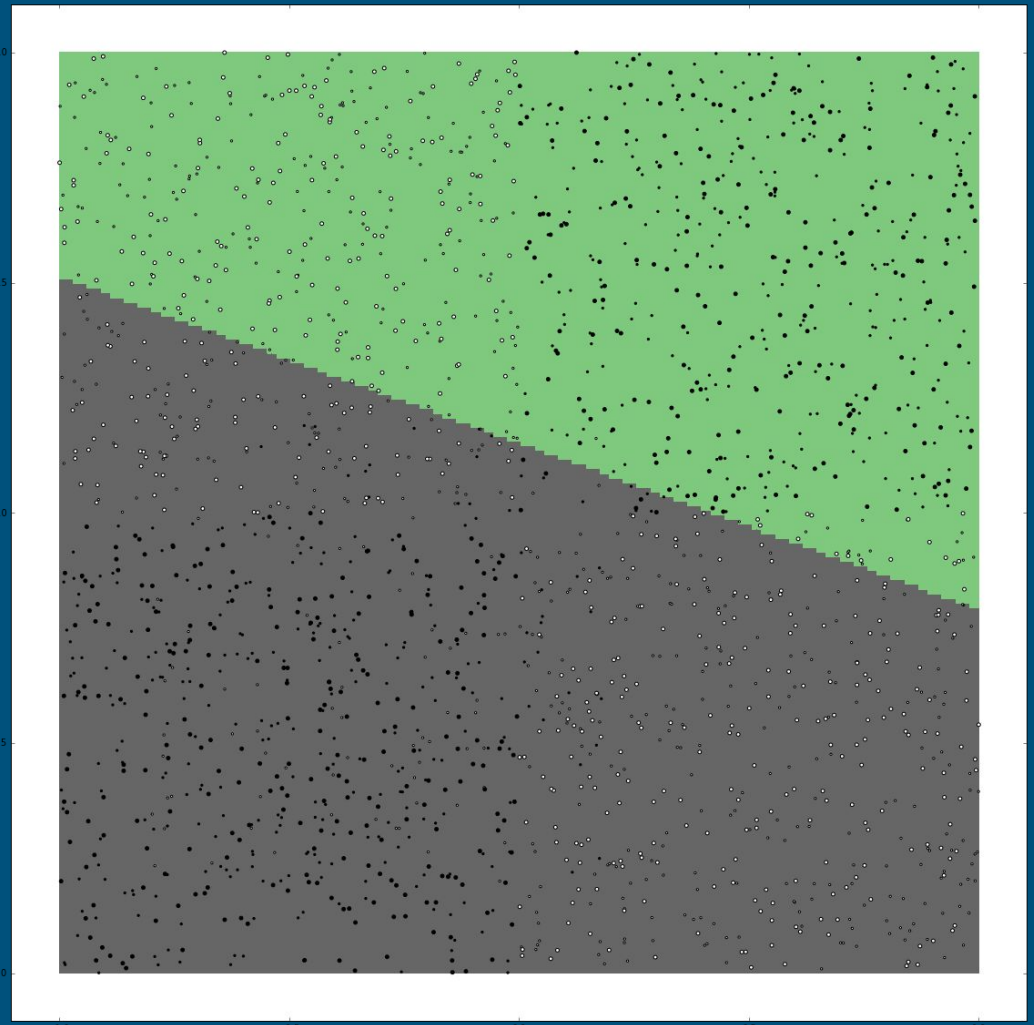
1.0
0.5
0.0
−0.5
−1.0
−1.0
−0.5
0.0
0.5
1.0

Clasificación con una red neuronal artificial de 1 capa escondida

```
 992/1000 [============================>.] - ETA: 0s
Test Accuracy con una capa oculta de 2 neuronas = 0.689000
 992/1000 [============================>.] - ETA: 0s
Test Accuracy con una capa oculta de 4 neuronas = 0.926000
1000/1000 [==============================] - 0s

Test Accuracy con una capa oculta de 8 neuronas = 0.919000
 992/1000 [============================>.] - ETA: 0s
Test Accuracy con una capa oculta de 16 neuronas = 0.962000
1100/1100 [==============================] - 0s
 992/1000 [============================>.] - ETA: 0s
Test Accuracy con una capa oculta de 32 neuronas = 0.961000
```

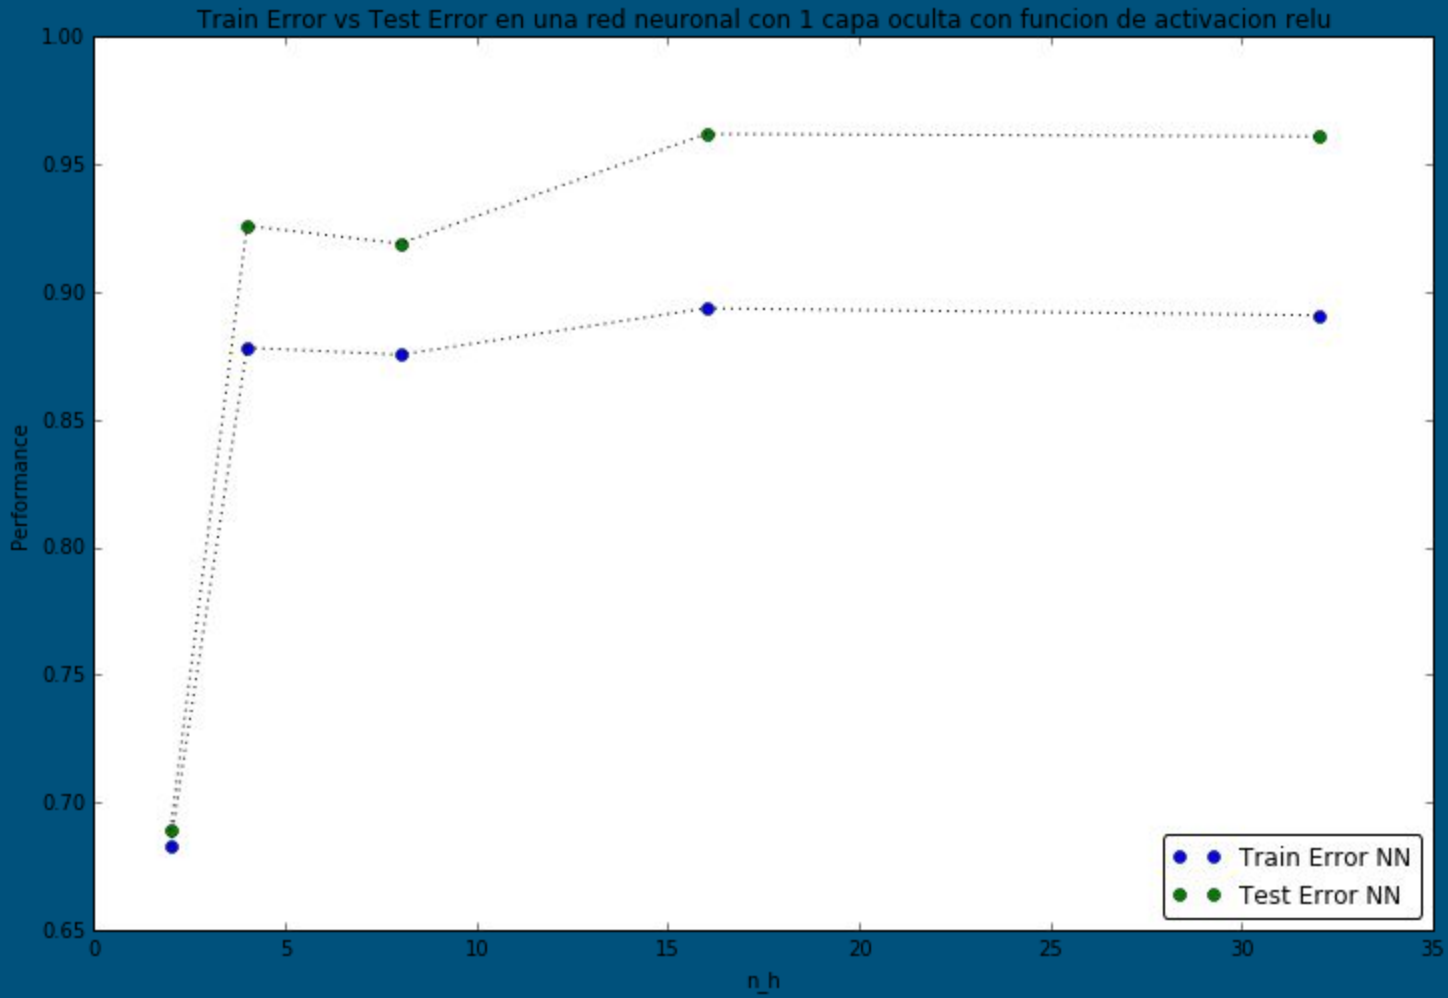
Train Error vs Test Error en una red neuronal con 1 capa oculta con funcion de activacion relu
Performance
n_h
1.00
0.95
0.90
0.85
0.80
0.75
0.70
0.65
0
5
10
15
20
25
30
35
Train Error NN
Test Error NN

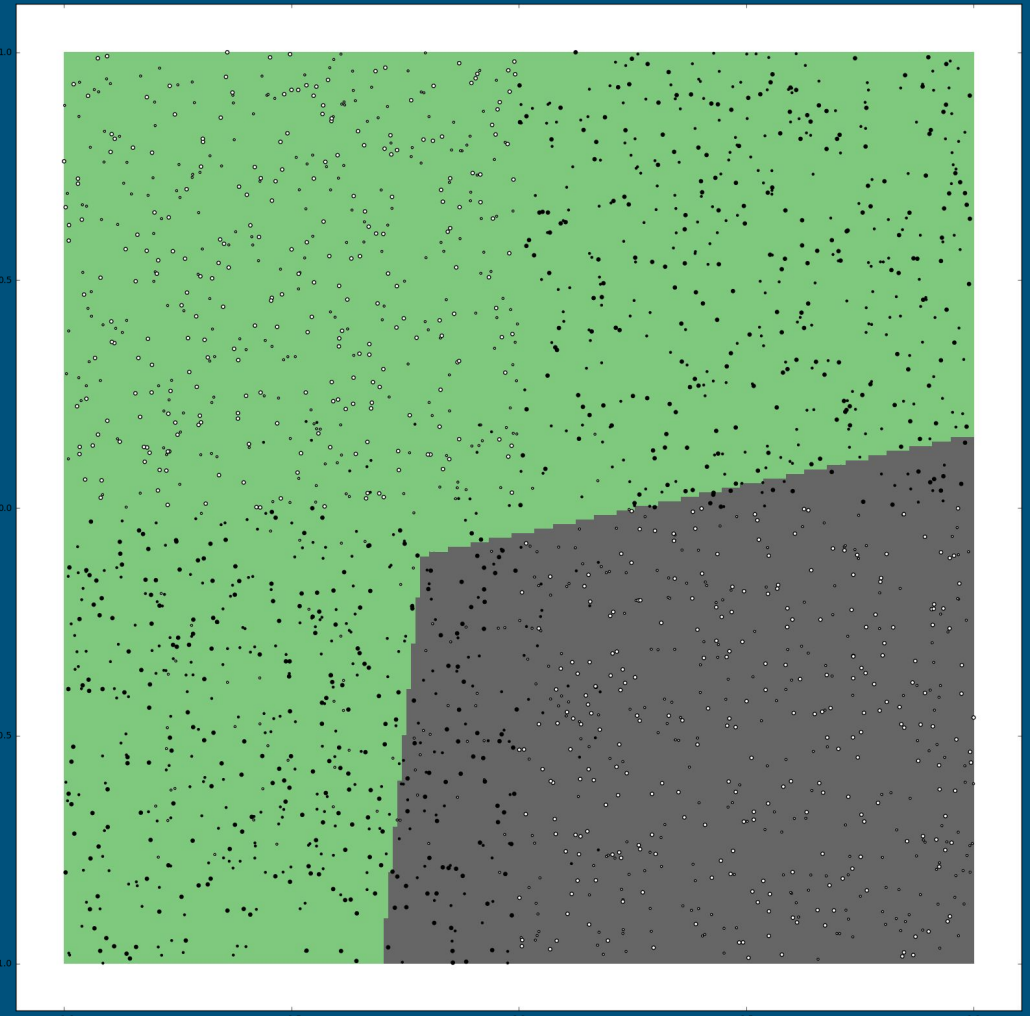
1.0
0.5
0.0
−0.5
−1.0
−1.0
−0.5
0.0
0.5
1.0

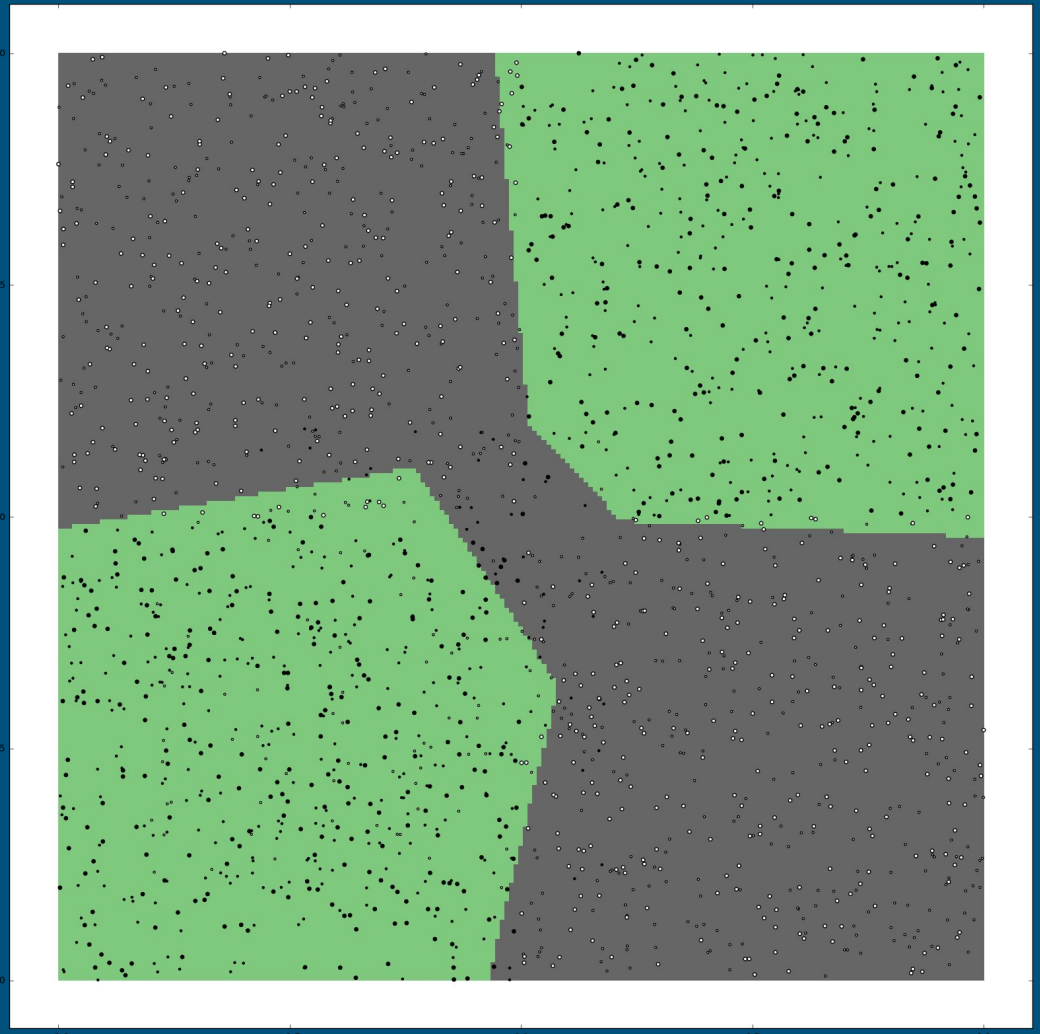
1.0
0.5
0.0
−0.5
−1.0
−1.0
−0.5
0.0
0.5
1.0

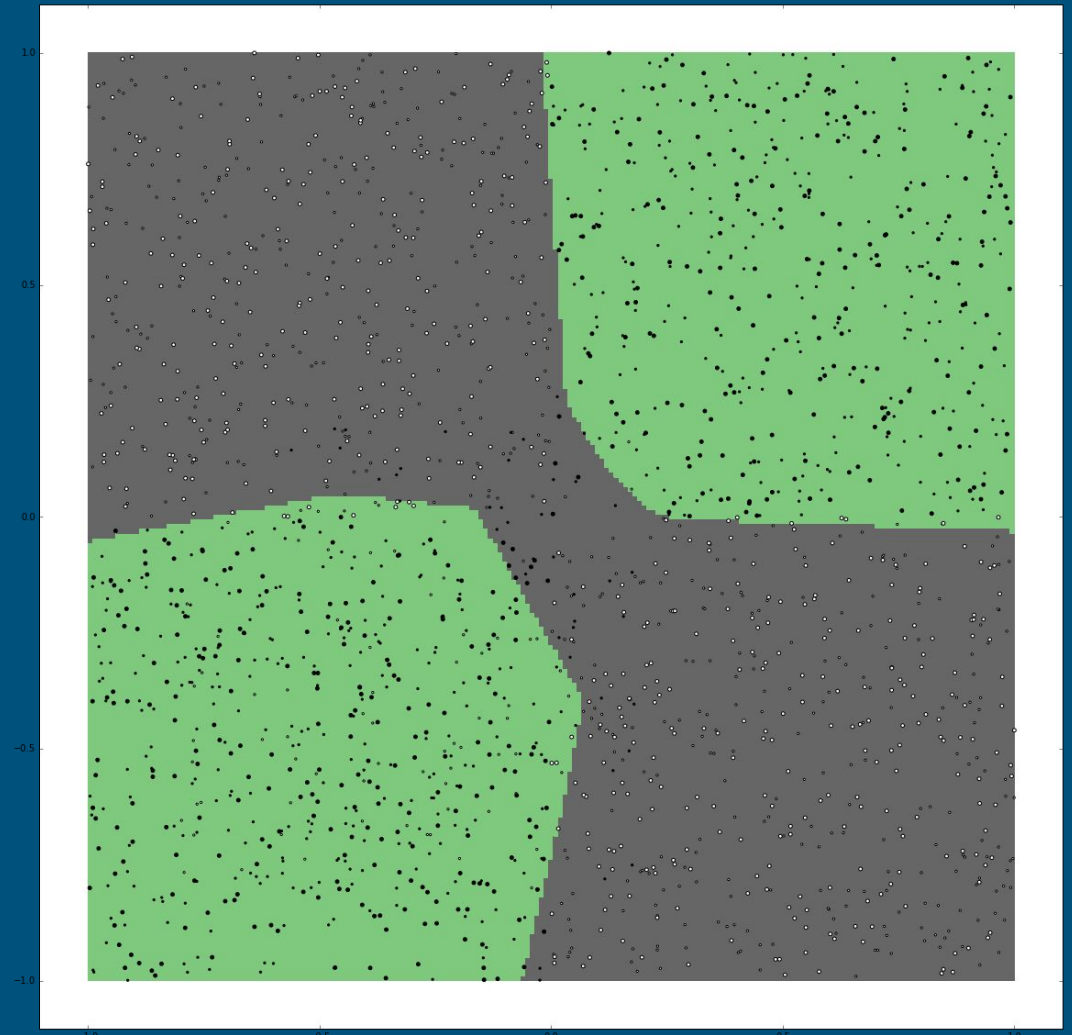
1.0
0.5
0.0
−0.5
−1.0
−1.0
−0.5
0.0
0.5
1.0

Clasificación con un árbol de 1 nivel

```
Training Accuracy Arbol con 1 nivel: 0.541818
Test Accuracy Arbol con 1 nivel: 0.489000
Detailed Analysis Testing Results ...
             precision    recall  f1-score   support

         -1       0.48      0.67      0.56       489
         +1       0.50      0.32      0.39       511

avg / total       0.49      0.49      0.47      1000
```

```
Test Accuracy = 0.489000
1
```

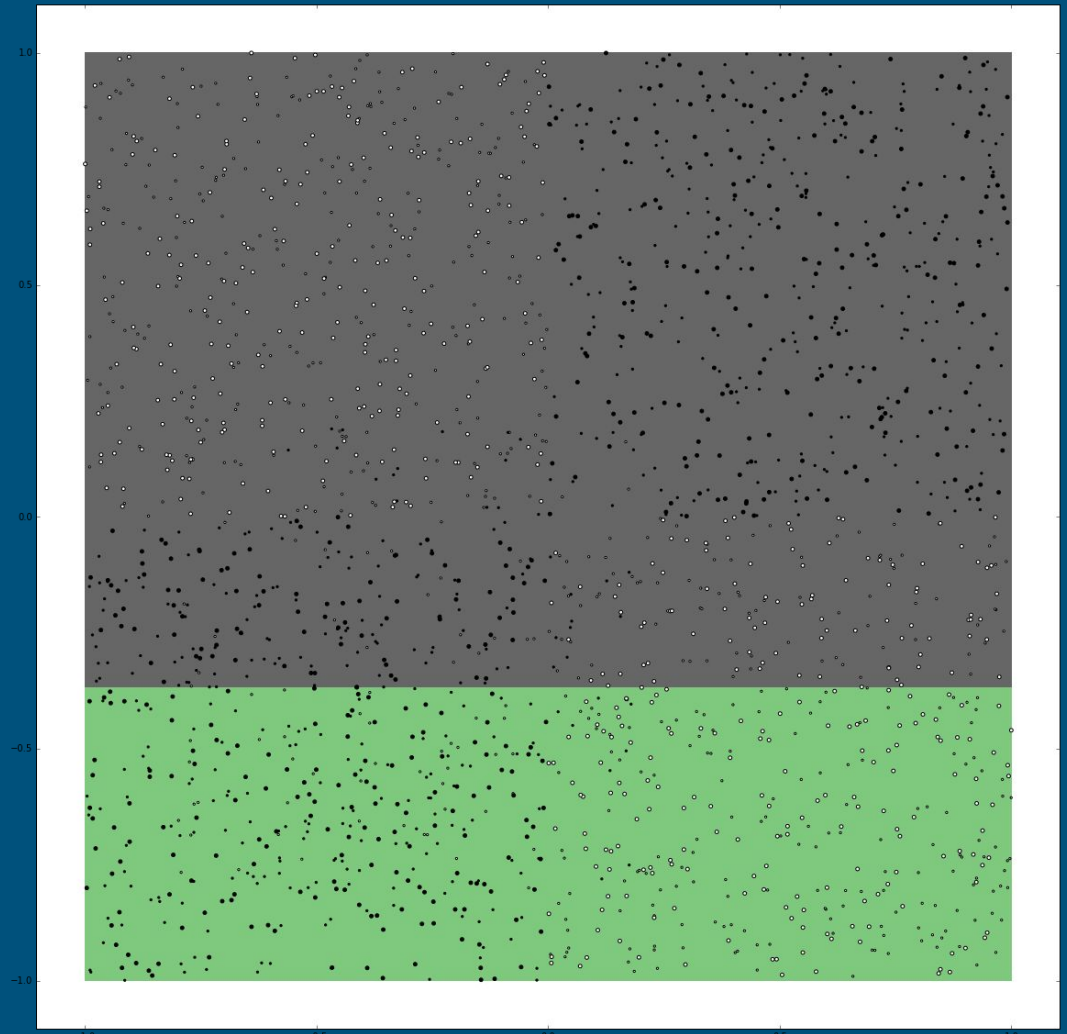

Clasificación con un árbol de múltiples niveles

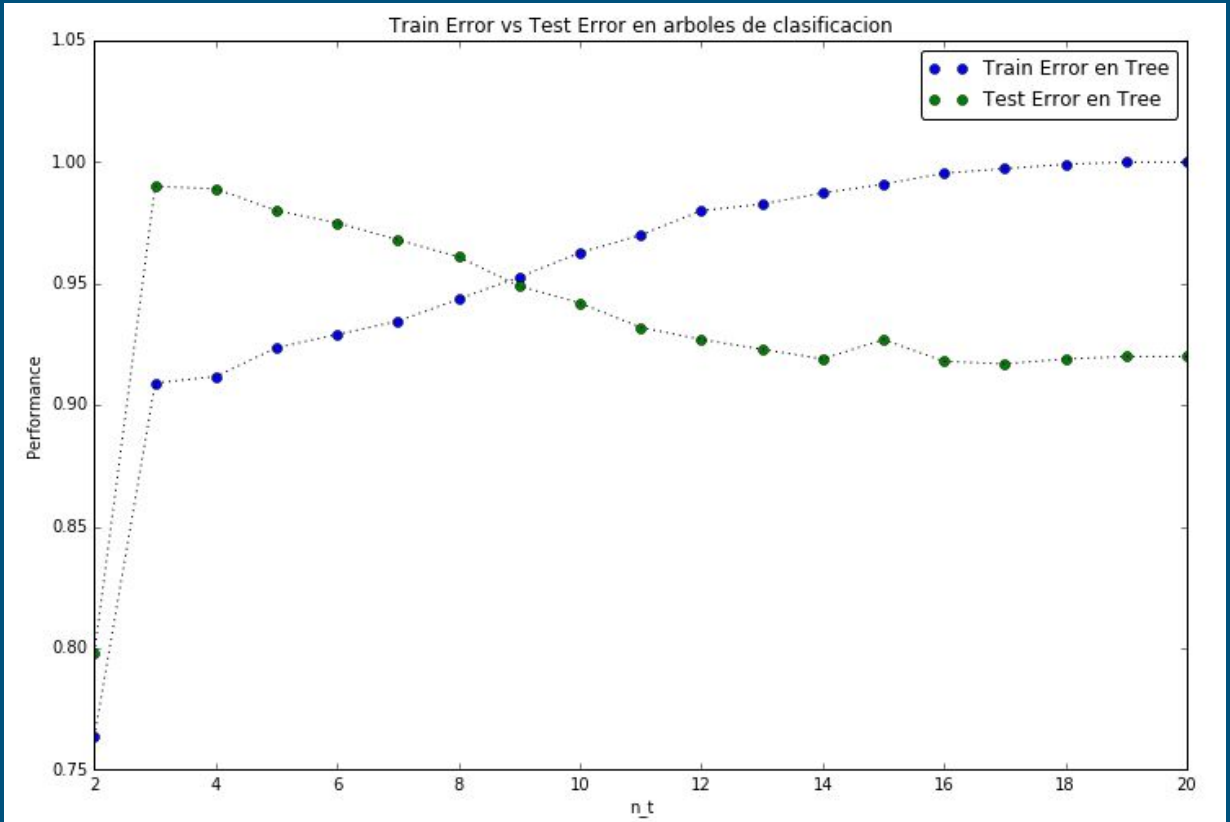

```
Clasicador Tree con n_t = 3
Test Accuracy = 0.990000
```

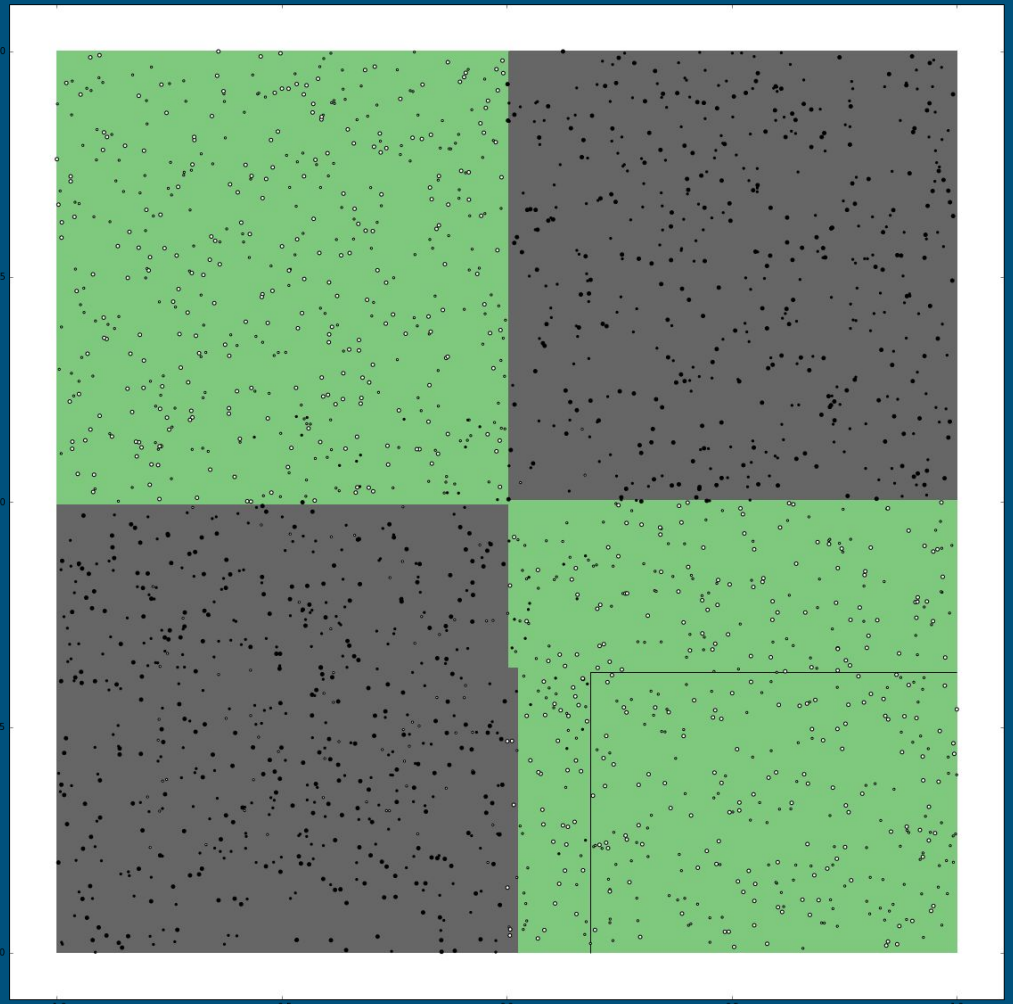

```
Clasicador Tree con n_t = 9
Test Accuracy = 0.949000
```

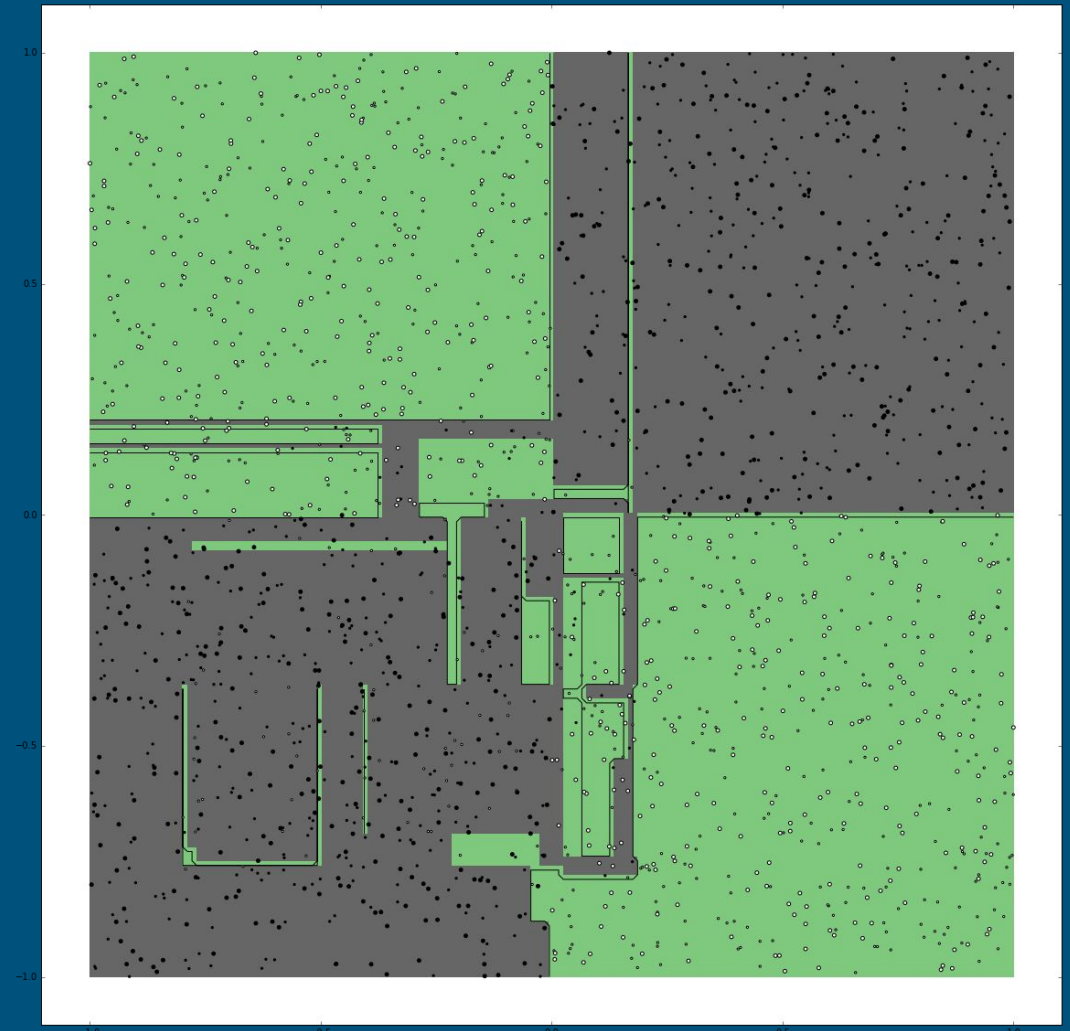

Clasicador Tree con n_t = 15
Test Accuracy = 0.927000

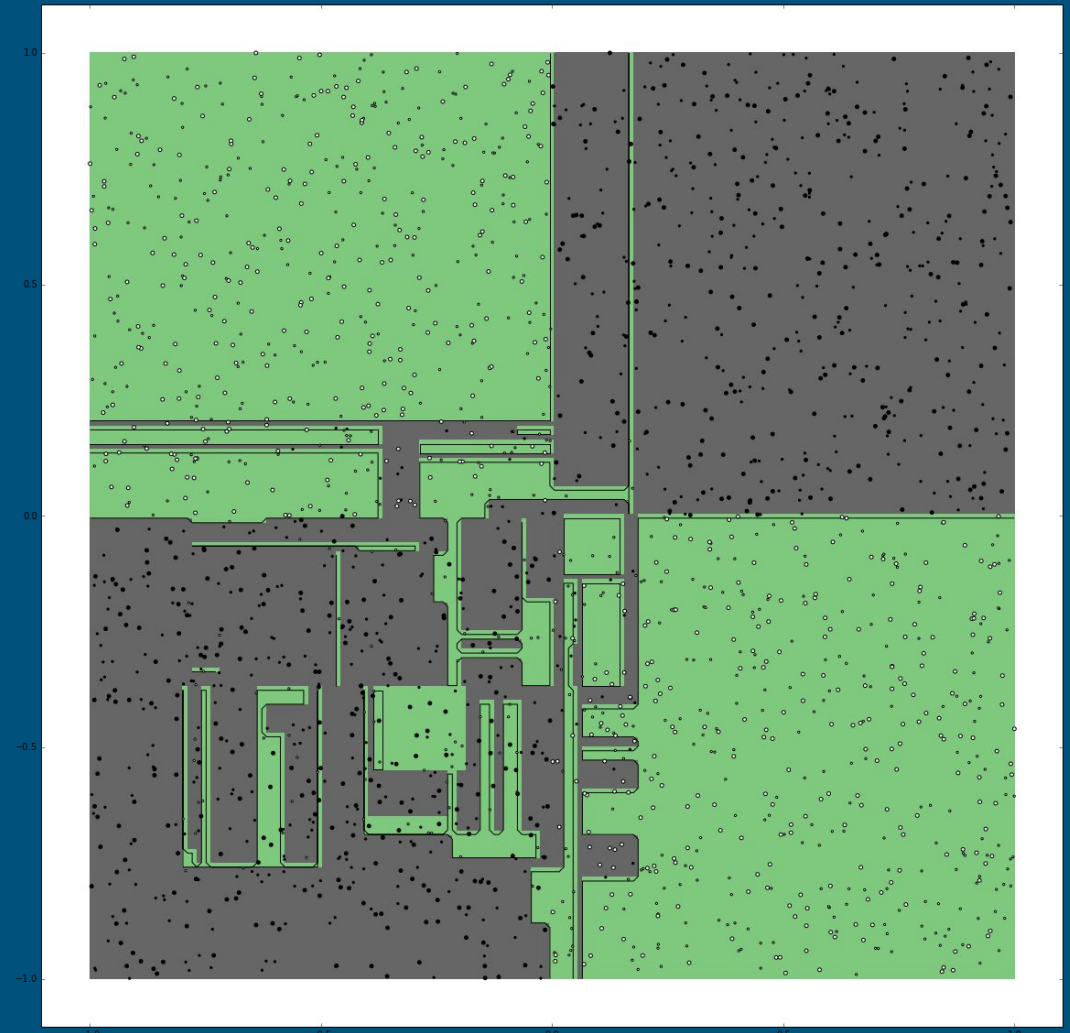

2. Bike Sharing: Predicción de Demanda Horaria

Contexto

- Los sistemas de intercambio de bicicletas son un medio para alquilar bicicletas en las que el proceso de obtención de membresía, alquiler y retorno de bicicletas se automatiza a través de una red de ubicaciones de quioscos en toda la ciudad.
- Utilizando estos sistemas, la gente puede alquilar una bicicleta desde una ubicación y devolverla a un lugar diferente según sea necesario.
- Se pide a los participantes que combinen los patrones de uso histórico con los datos meteorológicos para predecir la demanda de alquiler de bicicletas en el programa Capital Bikeshare en Washington, DC.

Contexto

Atributo	Descripción
datetime	hourly date + timestamp
season	1 = spring, 2 = summer, 3 = fall, 4 = winter
holiday	whether the day is considered a holiday
workingday	whether the day is neither a weekend nor holiday
weather	1: Clear, Few clouds, Partly cloudy, Partly cloudy
	2: Mist + Cloudy, Mist + Broken clouds, Mist + Few clouds, Mist
	3: Light Snow, Light Rain + Thunderstorm + Scattered clouds, Light Rain + Scattered clouds
	4: Heavy Rain + Ice Pallets + Thunderstorm + Mist, Snow + Fog
temp	temperature in Celsius
atemp	"feels like" temperature in Celsius
humidity	relative humidity
windspeed	wind speed
casual	number of non-registered user rentals initiated
registered	number of registered user rentals initiated
count	number of total rentals

Contexto

Se desea obtener el mejor puntaje posible para la función proporcionada para el concurso:

$$E_{bikes}(y, \hat{y}) = \frac{1}{x} \sum_{i} (\ln(y_i + 1) - \ln(\hat{y}_i + 1))^2$$

En donde y e ŷ son los valores reales y de predicción respectivamente.

Se construye un dataframe extrayendo el valor de la hora del día desde los datos de fecha y hora de registro para incorporarlos como característica numérica al problema.

Summary - dataframe completo:

	Unnamed: 0	season	holiday	workingday	weather
count	10886.000000	10886.000000	10886.000000	10886.000000	10886.000000
mean	5442.500000	2.506614	0.028569	0.680875	1.418427
std	3142.661849	1.116174	0.166599	0.466159	0.633839
min	0.000000	1.000000	0.000000	0.000000	1.000000
25%	2721.250000	2.000000	0.000000	0.000000	1.000000
50%	5442.500000	3.000000	0.000000	1.000000	1.000000
75%	8163.750000	4.000000	0.000000	1.000000	2.000000
max	10885.000000	4.000000	1.000000	1.000000	4.000000

	temp	atemp	humidity	windspeed	casual
count	10886.00000	10886.000000	10886.000000	10886.000000	10886.000000
mean	20.23086	23.655084	61.886460	12.799395	36.021955
std	7.79159	8.474601	19.245033	8.164537	49.960477
min	0.82000	0.760000	0.000000	0.000000	0.000000
25%	13.94000	16.665000	47.000000	7.001500	4.000000
50%	20.50000	24.240000	62.000000	12.998000	17.000000
75%	26.24000	31.060000	77.000000	16.997900	49.000000
max	41.00000	45.455000	100.000000	56.996900	367.000000

	registered	count
count	10886.000000	10886.000000
mean	155.552177	191.574132
std	151.039033	181.144454
min	0.000000	1.000000
25%	36.000000	42.000000
50%	118.000000	145.000000
75%	222.000000	284.000000
max	886.000000	977.000000

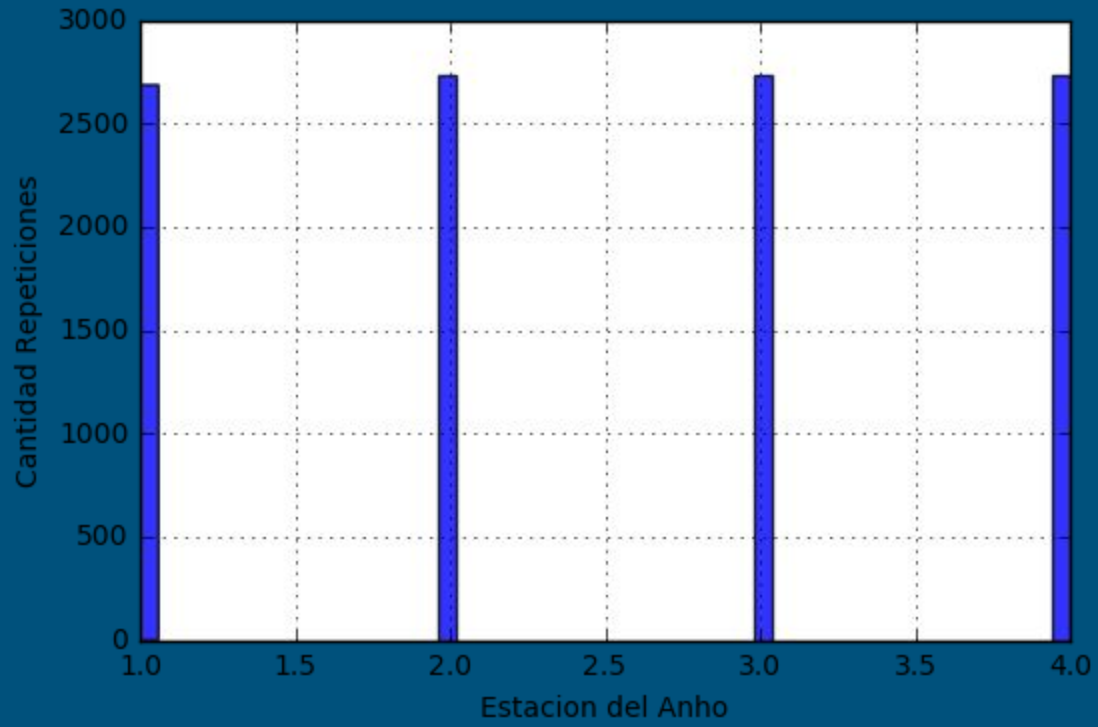
3000
2500
2000
1500
1000
500
0
Cantidad Repeticiones
1.0
1.5
2.0
2.5
3.0
3.5
4.0
Estacion del Anho

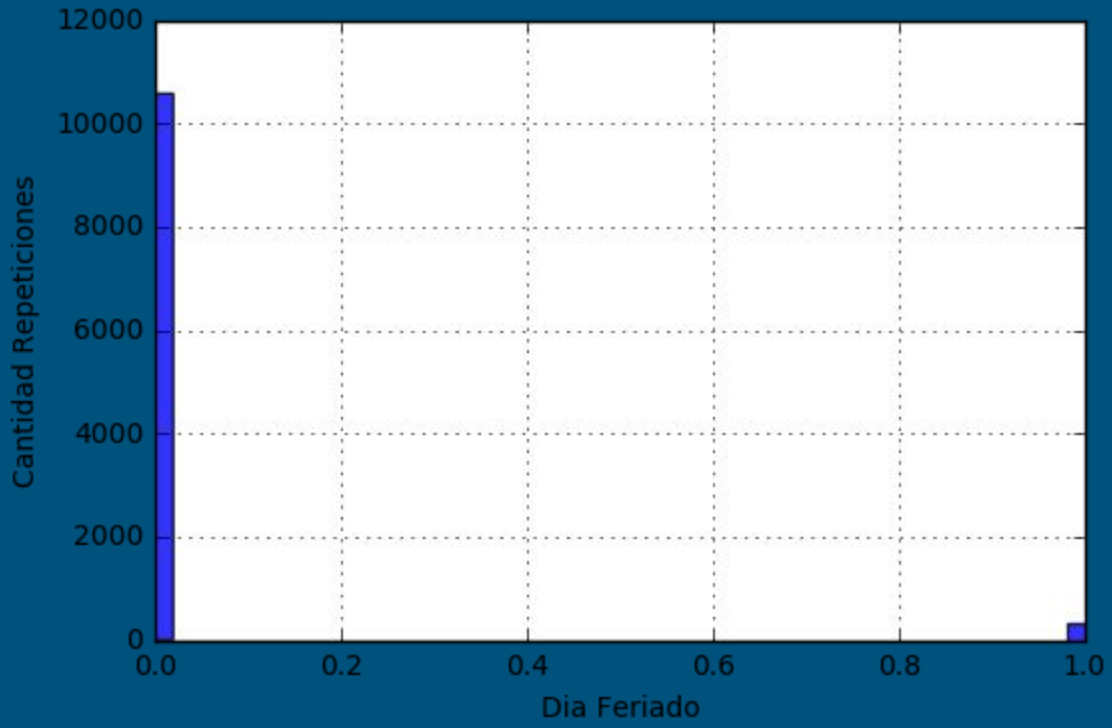
12000
10000
8000
6000
4000
2000
0
Cantidad Repeticiones
0.0
0.2
0.4
0.6
0.8
1.0
Dia Feriado

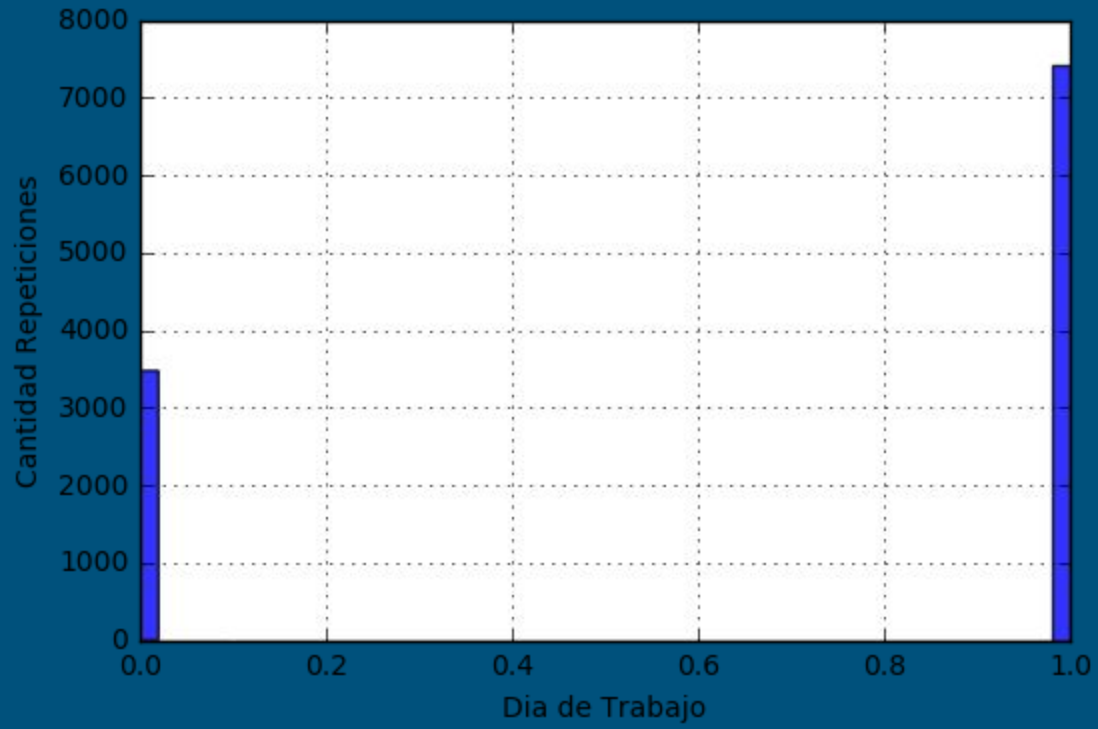
8000
7000
6000
5000
4000
3000
2000
1000
0
Cantidad Repeticiones
0.0
0.2
0.4
0.6
0.8
1.0
Dia de Trabajo

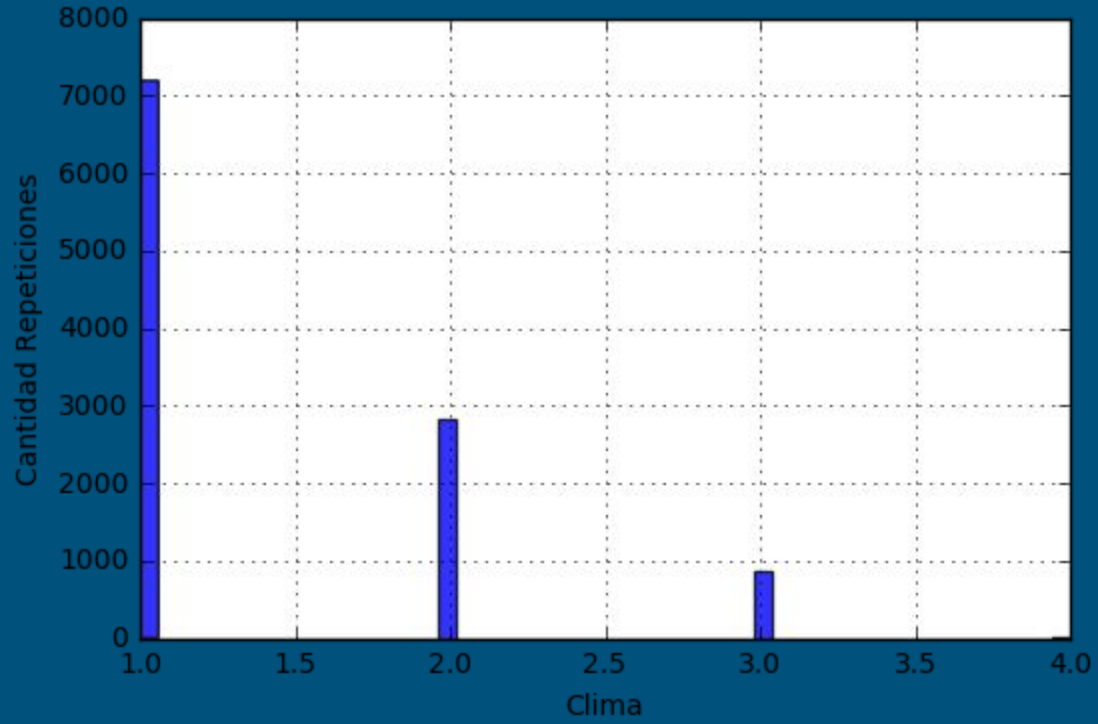
8000
7000
6000
5000
4000
3000
2000
1000
0
Cantidad Repeticiones
1.0
1.5
2.0
2.5
3.0
3.5
4.0
Clima

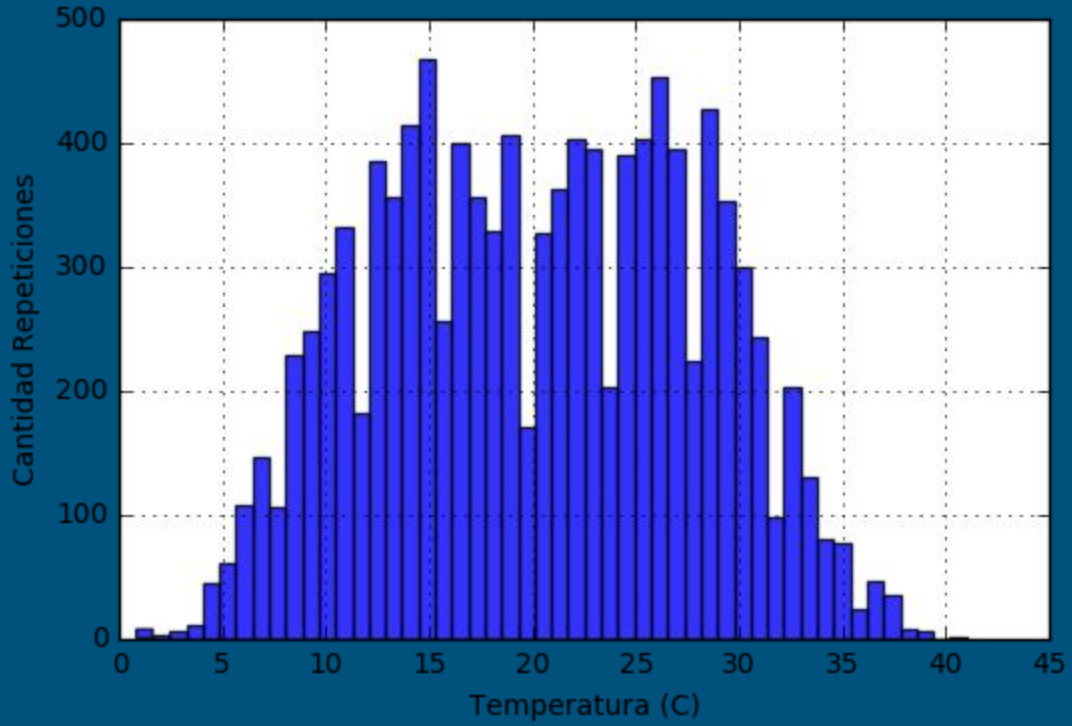
Cantidad Repeticiones
Temperatura (C)
0
100
200
300
400
500
0
5
10
15
20
25
30
35
40
45

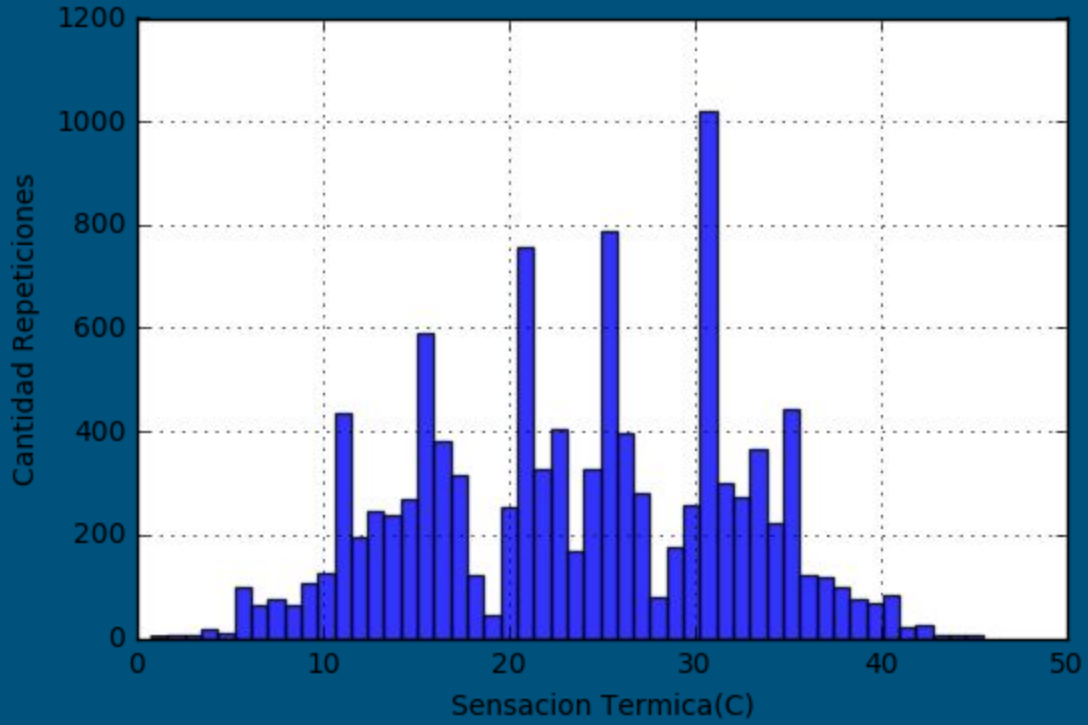
1200
1000
800
600
400
200
0
Cantidad Repeticiones
0
10
20
30
40
50
Sensacion Termica(C)

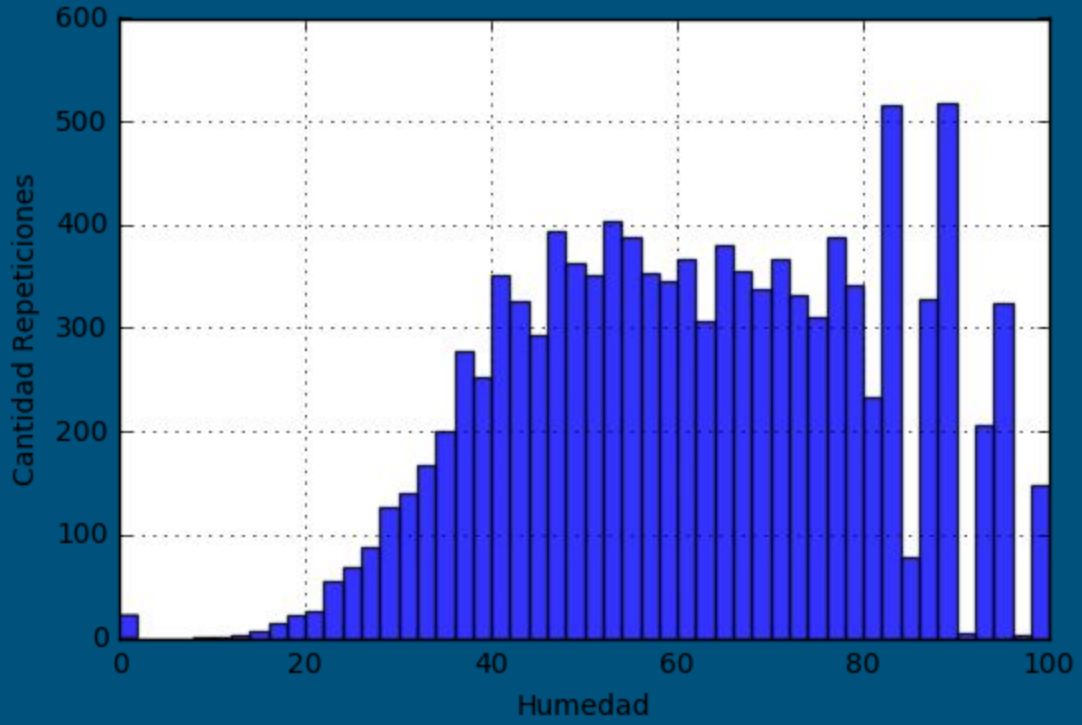
600
500
400
300
200
100
0
Cantidad Repeticiones
0
20
40
60
80
100
Humedad

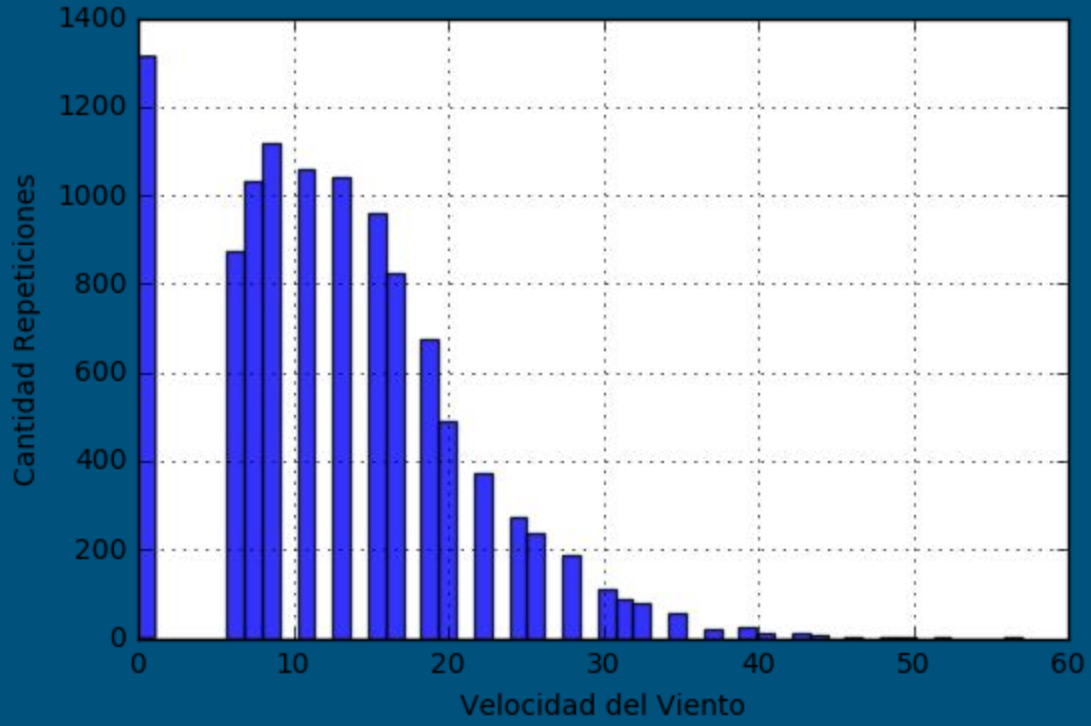
1400
1200
1000
800
600
400
200
0
Cantidad Repeticiones
0
10
20
30
40
50
60
Velocidad del Viento

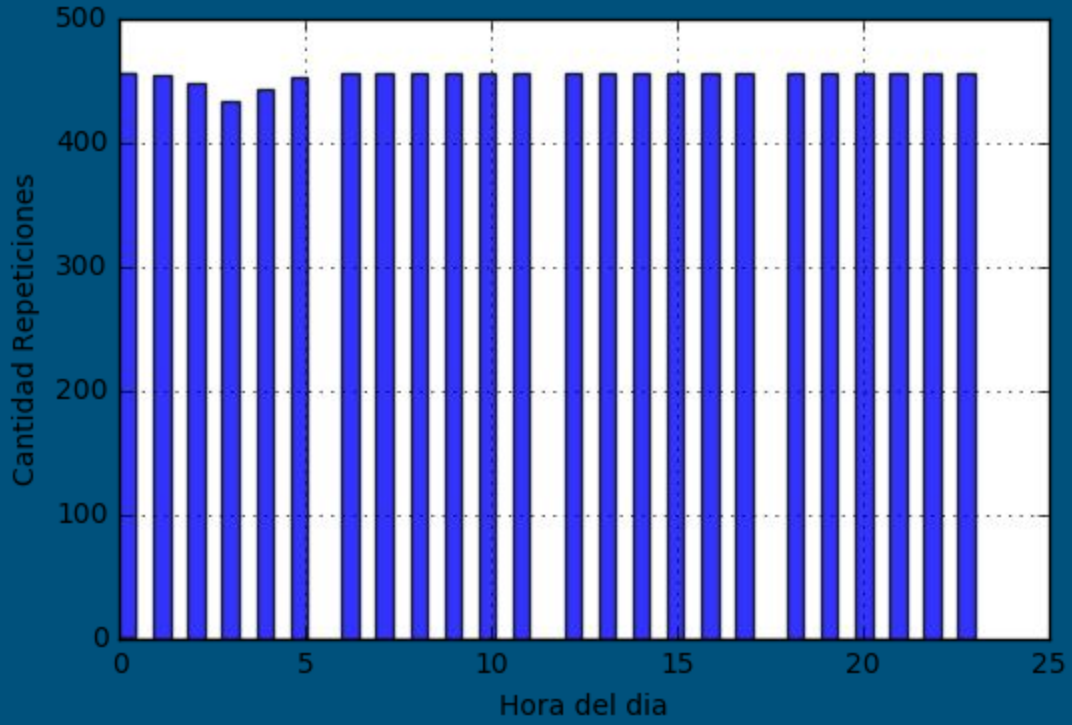
500
400
300
200
100
0
Cantidad Repeticiones
0
5
10
15
20
25
Hora del dia

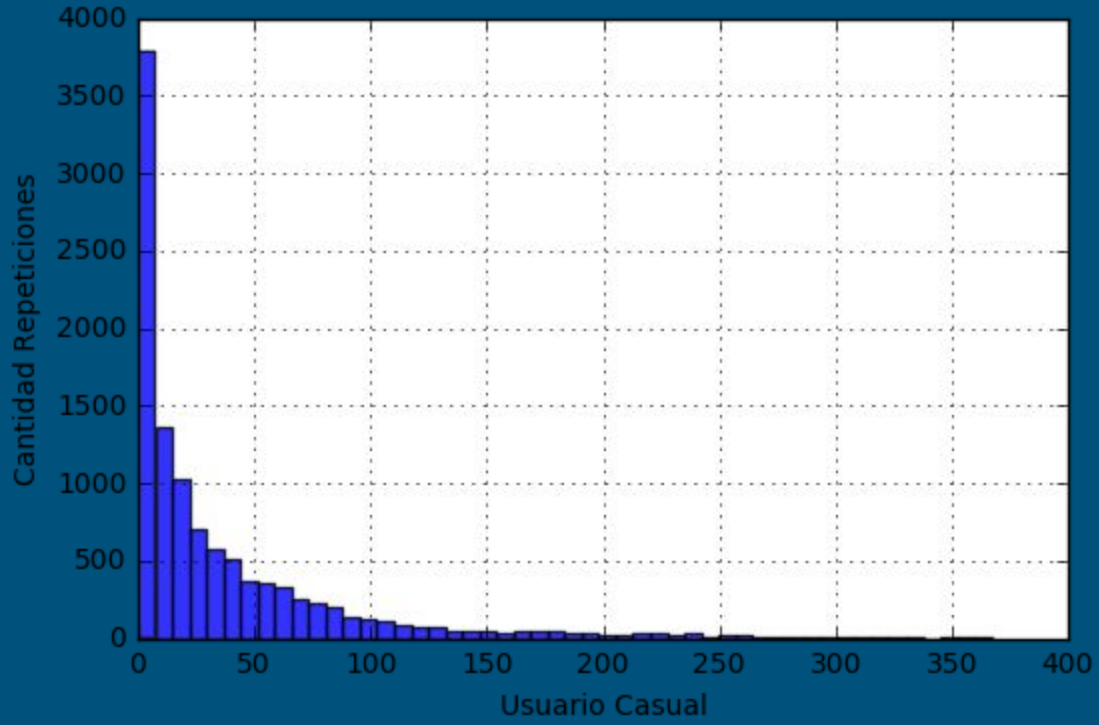
4000
3500
3000
2500
2000
1500
1000
500
0
Cantidad Repeticiones
0
50
100
150
200
250
300
350
400
Usuario Casual

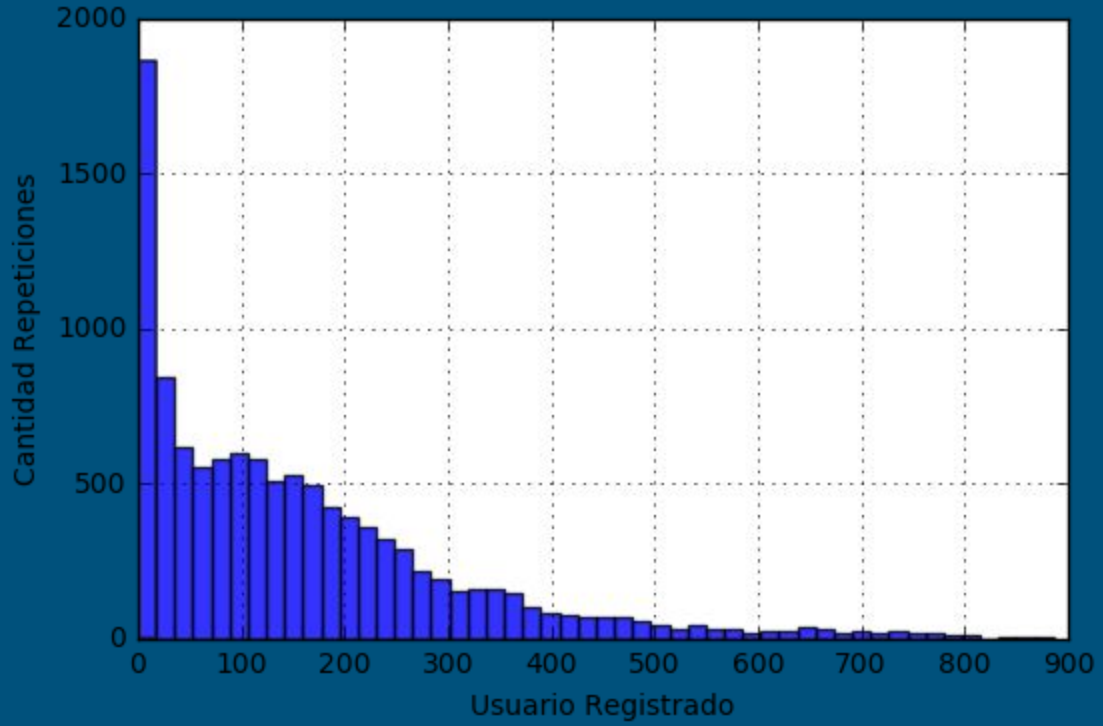
2000
1500
1000
500
0
Cantidad Repeticiones
0
100
200
300
400
500
600
700
800
900
Usuario Registrado

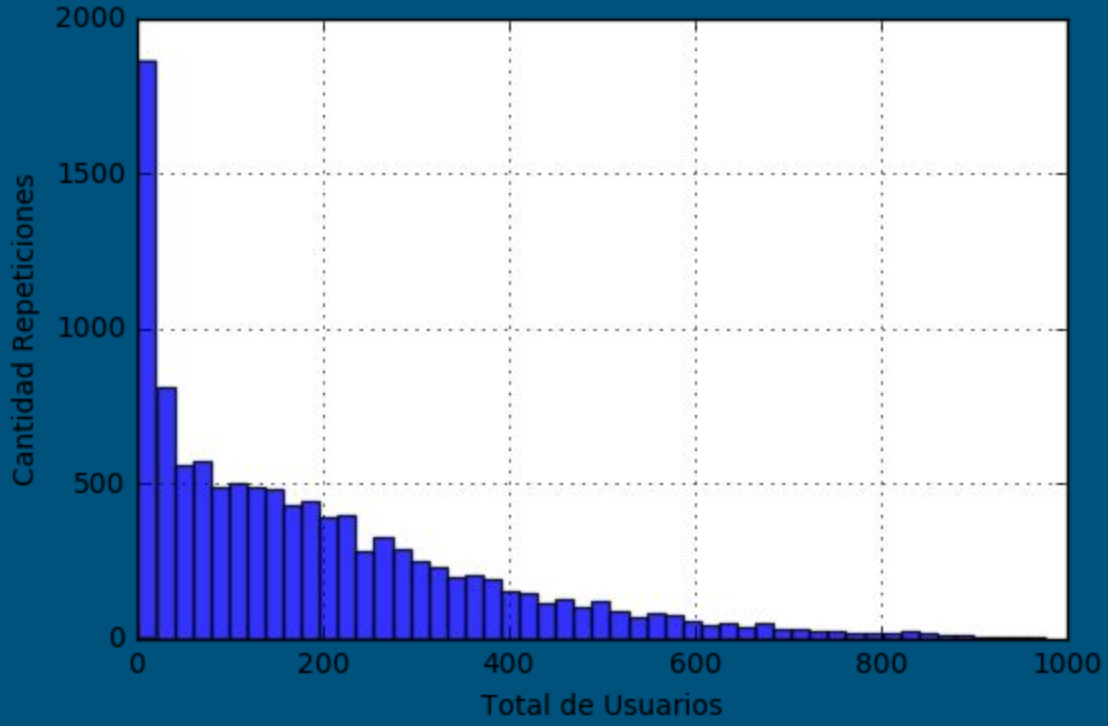
2000
1500
1000
500
0
Cantidad Repeticiones
0
200
400
600
800
1000
Total de Usuarios

Entrenar un árbol de regresión

```
SCORE TEST=0.703261
KAGG EVAL TRAIN =0.028516
KAGG EVAL TEST =0.574539
KAGG EVAL VALIDATION =0.553973
```

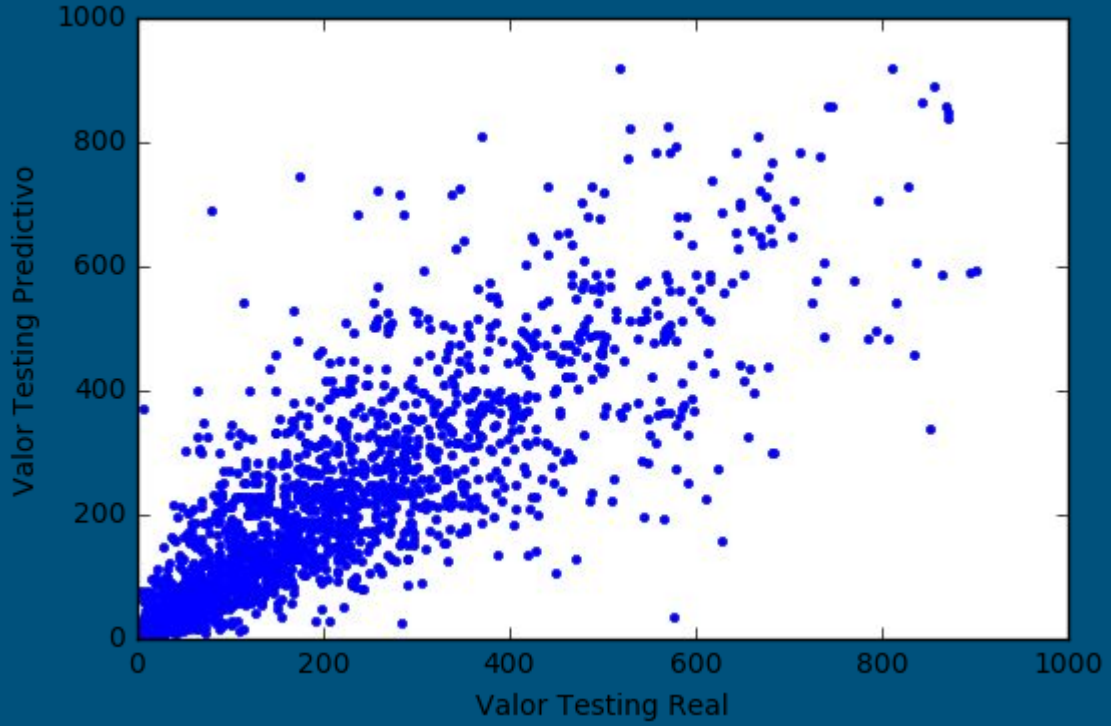

Mejorar el árbol (hiper-parámetros)

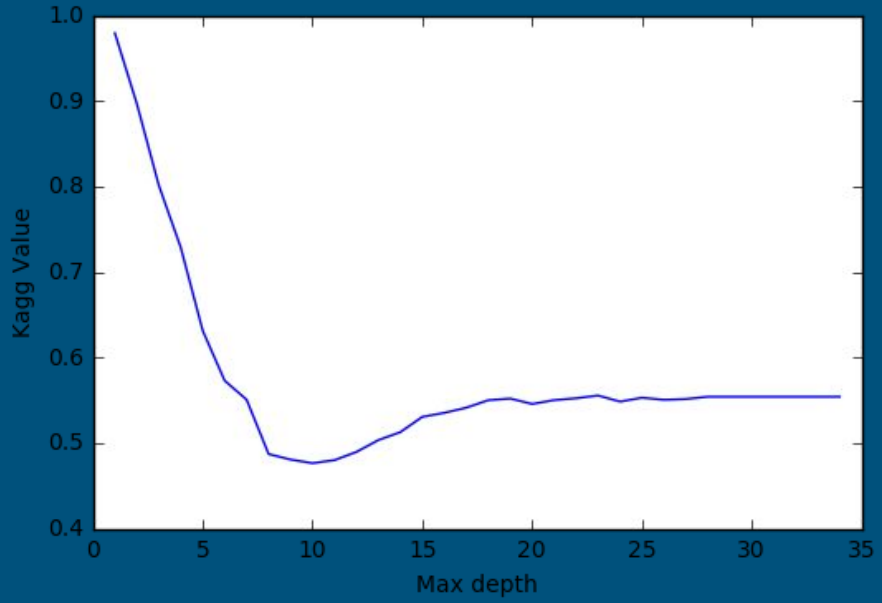

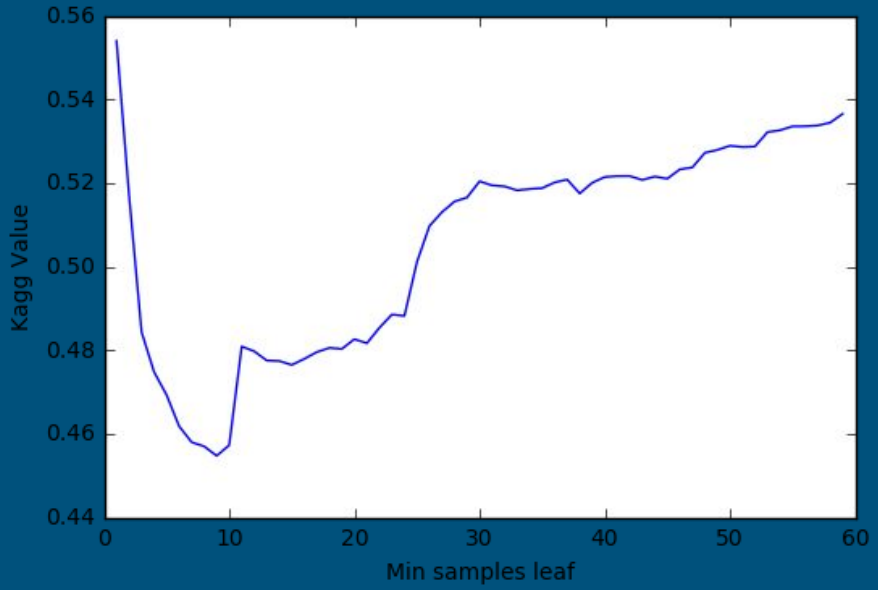

Mejorar el árbol (hiper-parámetros)

```
Mejor valor para máximo niveles: 10
Mejor valor para mínimo de datos por hoja: 9
```

```
KAGG EVAL VAL =0.451062
```

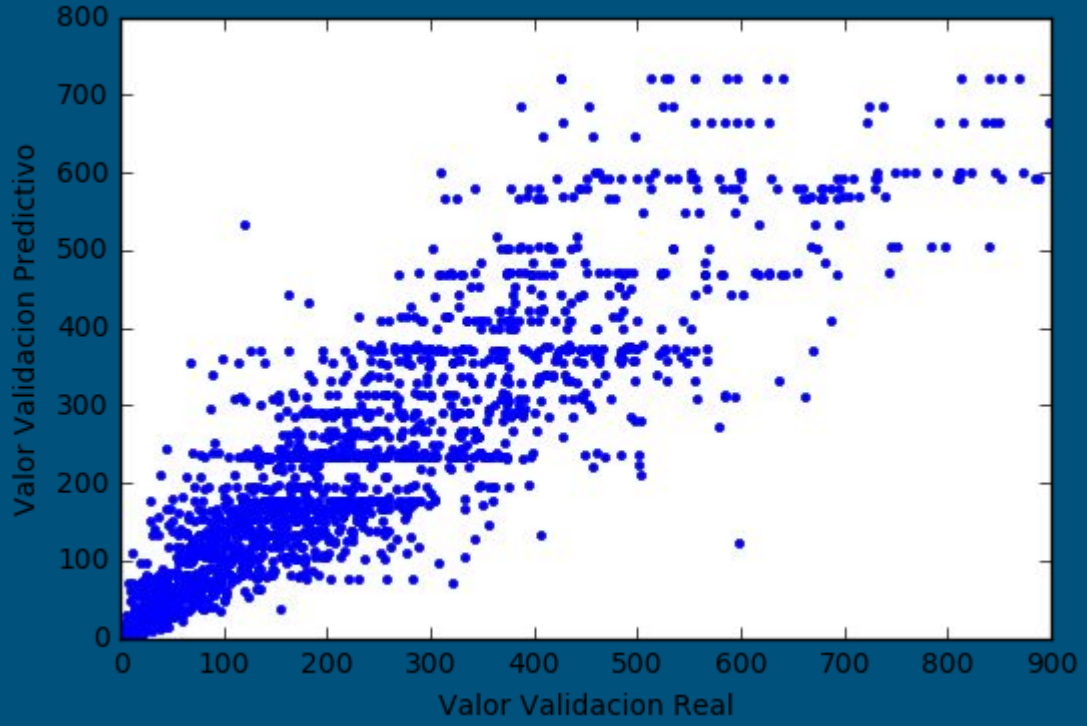

Mejorar el árbol de regresión (datos)

- Se extrajo mayor información desde los datos: mes y año.
- Se aplicó la función logaritmo natural a los datos de conteo de préstamos de bicicletas (count).
- Se intentó además aplicar funciones de logaritmo o raíz a la velocidad del viento y ajustar a una normal los valores de las temperaturas, pero no se obtuvo tan buenos resultados por lo que se excluyeron.

Mejorar el árbol de regresión (datos)

```
KAGG EVAL VALIDATION =0.402686
```

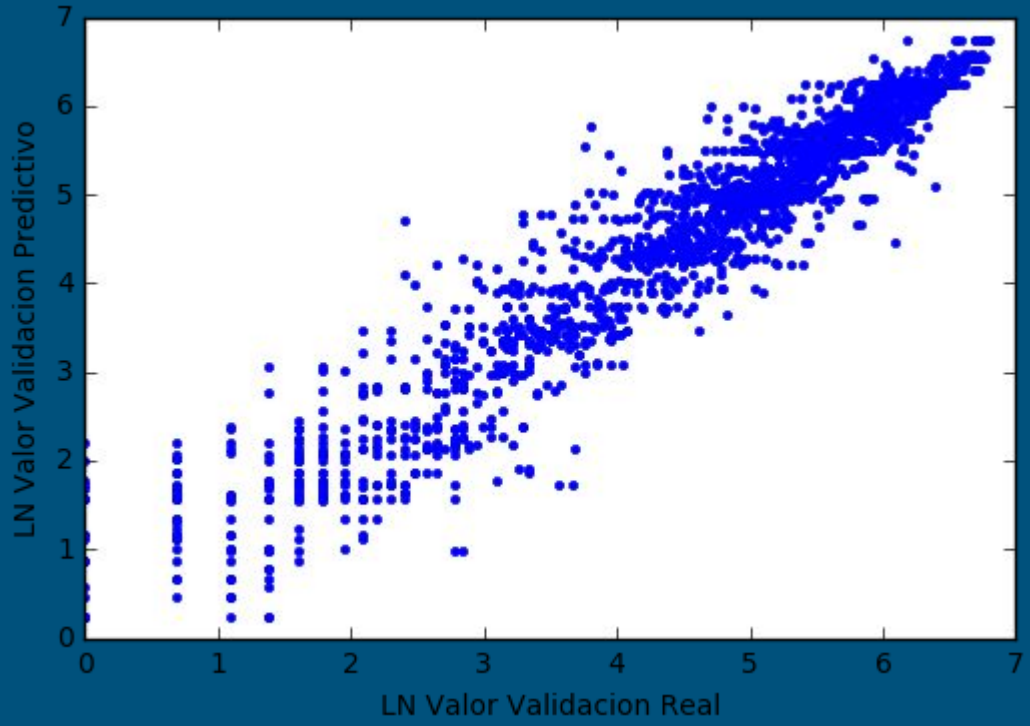

Entrenar SVM no lineal

- Se entrenó con parámetros por defecto (C=1, épsilon=0.1).
- Los datos anteriormente manipulados recibieron un escalamiento para hacerlos comparables.
- Los datos categóricos recibieron una transformación de tal forma que queden representados como valores binarios, trinarios u otros dependiendo de la cantidad de valores posibles a tomar.

Entrenar SVM no lineal

```
KAGG EVAL VALIDATION =0.292625
```

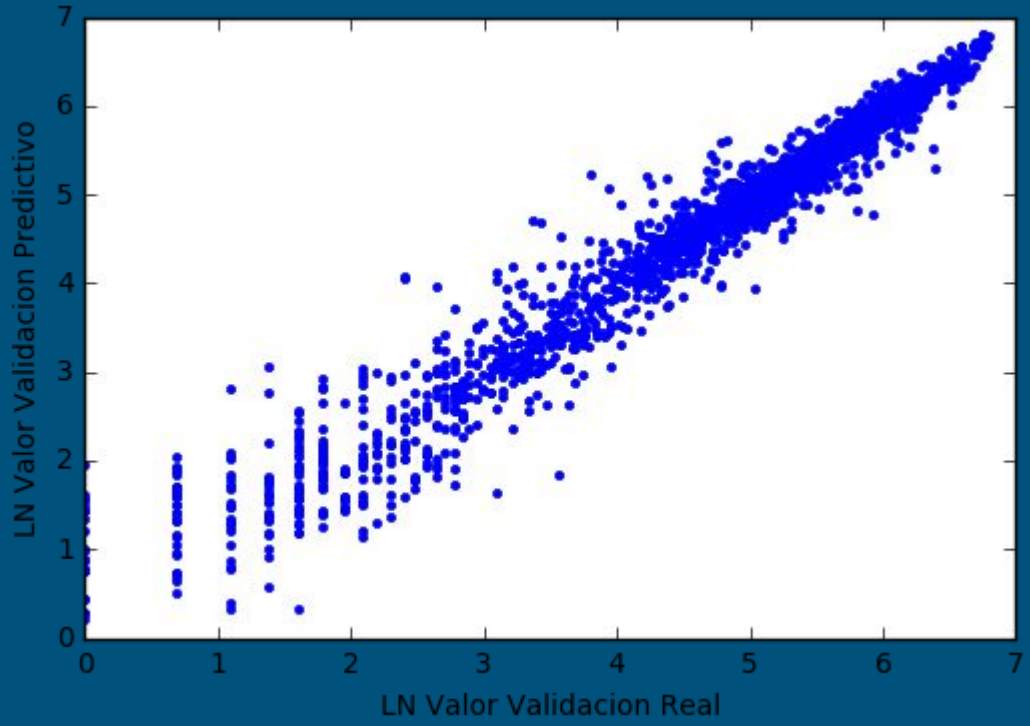

Mejorar la SVM (parámetros)

```
Mejores valores: C= 1.600000 , epsilon = 0.050000,
```

```
KAGG EVAL TRAIN =0.220828
KAGG EVAL VAL =0.287996
```

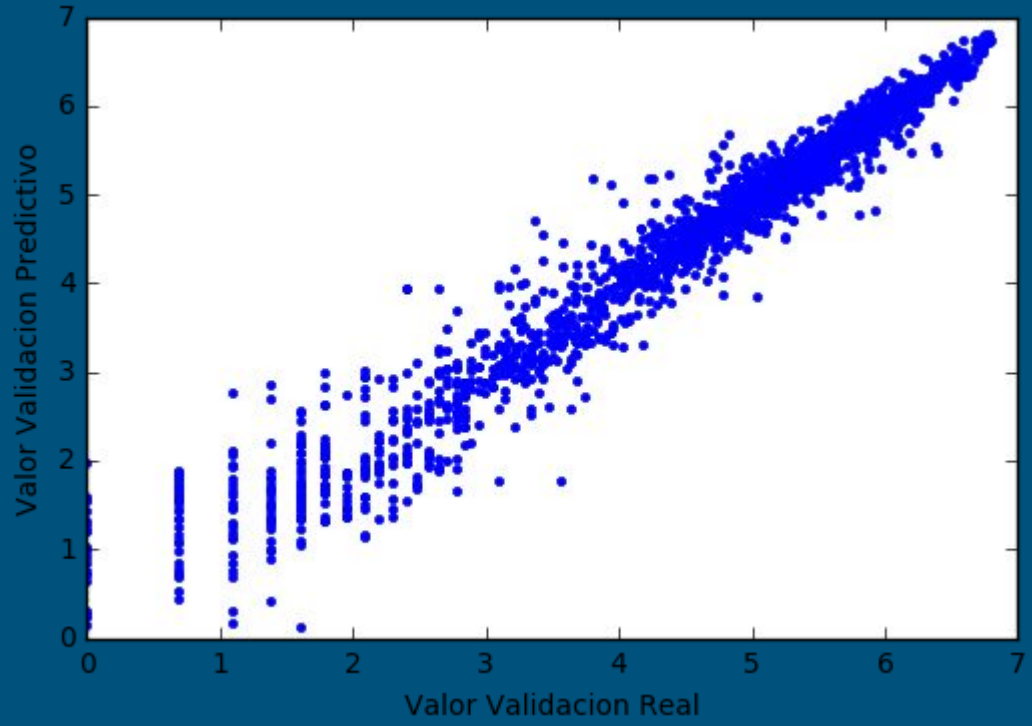

Evaluar usando Cross Validation(árbol)

```
-------------TREE--------------
MAX depth= 9    MIN leaf= 3   =>  kaggeval= 0.452973

MAX depth= 10    MIN leaf= 3   =>  kaggeval= 0.437493

MAX depth= 11    MIN leaf= 3   =>  kaggeval= 0.432979

MAX depth= 12    MIN leaf= 6   =>  kaggeval= 0.430801

MAX depth= 13    MIN leaf= 3   =>  kaggeval= 0.429883

MAX depth= 13    MIN leaf= 6   =>  kaggeval= 0.427722

MAX depth= 14    MIN leaf= 6   =>  kaggeval= 0.427608

MAX depth= 15    MIN leaf= 6   =>  kaggeval= 0.427535

MAX depth= 16    MIN leaf= 6   =>  kaggeval= 0.427143
```

Evaluar usando Cross Validation(SVM)

```
--------------SVM--------------
C= 1.000000  epsilon = 0.050000   =>  kaggeval= 0.305019

C= 1.200000  epsilon = 0.050000   =>  kaggeval= 0.303537

C= 1.200000  epsilon = 0.100000   =>  kaggeval= 0.303391

C= 1.400000  epsilon = 0.050000   =>  kaggeval= 0.302621

C= 1.400000  epsilon = 0.100000   =>  kaggeval= 0.302329

C= 1.500000  epsilon = 0.100000   =>  kaggeval= 0.302113

C= 1.600000  epsilon = 0.100000   =>  kaggeval= 0.302070
```

Ensamblar dos máquinas según predicción de tipo de usuario

- Entrenando dos máquinas SVM especializadas en el conteo de personas registradas y otra que no (casuales).

- Esto mismo podría aplicarse con otros tipos de especialización, como considerar todo lo que tenga que referencia con fechas y horas, o con lo que tiene que ver con clima y dificultades físicas y prácticas para los ciclistas.

Ensamblar dos máquinas según predicción de tipo de usuario

```
KAGG EVAL TEST =0.307498
```

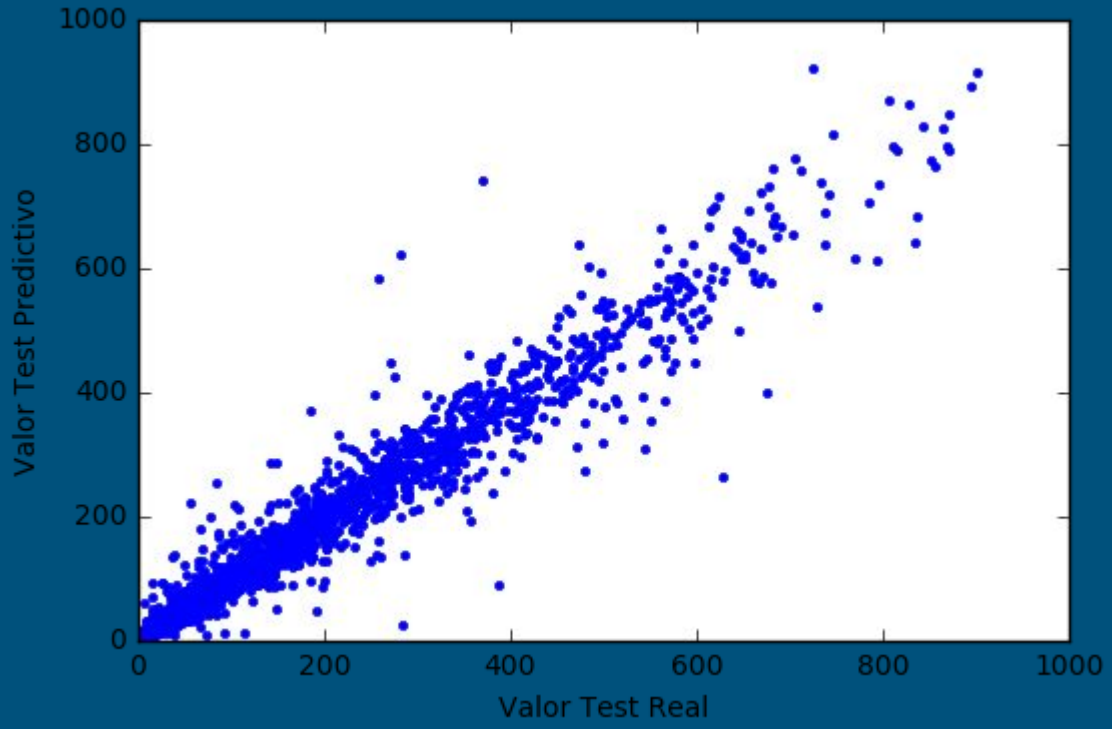

Evaluar algoritmo genérico de ensamblado

```
Para 5 Máquinas se obtiene KAGG EVAL TRAIN = 0.273225
Para 6 Máquinas se obtiene KAGG EVAL TRAIN = 0.271616
Para 7 Máquinas se obtiene KAGG EVAL TRAIN = 0.270044
Para 8 Máquinas se obtiene KAGG EVAL TRAIN = 0.268881
Para 9 Máquinas se obtiene KAGG EVAL VAL = 0.335720
Para 9 Máquinas se obtiene KAGG EVAL TRAIN = 0.267157
Para 10 Máquinas se obtiene KAGG EVAL VAL = 0.334814
Para 10 Máquinas se obtiene KAGG EVAL TRAIN = 0.265822
Para 12 Máquinas se obtiene KAGG EVAL VAL = 0.334478
Para 14 Máquinas se obtiene KAGG EVAL VAL = 0.334191
Para 14 Máquinas se obtiene KAGG EVAL TRAIN = 0.265456
Para 15 Máquinas se obtiene KAGG EVAL VAL = 0.334136
Para 16 Máquinas se obtiene KAGG EVAL VAL = 0.333387
Para 16 Máquinas se obtiene KAGG EVAL TRAIN = 0.264784
Para 17 Máquinas se obtiene KAGG EVAL TRAIN = 0.264611
Para 18 Máquinas se obtiene KAGG EVAL VAL = 0.332804
Para 18 Máquinas se obtiene KAGG EVAL TRAIN = 0.263571
Para 19 Máquinas se obtiene KAGG EVAL TRAIN = 0.263400
Para 20 Máquinas se obtiene KAGG EVAL VAL = 0.332268
Para 20 Máquinas se obtiene KAGG EVAL TRAIN = 0.262958
```

```
Para 25 Máquinas se obtiene KAGG EVAL VAL = 0.330871
Para 25 Máquinas se obtiene KAGG EVAL TRAIN = 0.262782
Para 26 Máquinas se obtiene KAGG EVAL VAL = 0.330431
Para 26 Máquinas se obtiene KAGG EVAL TRAIN = 0.262662
Para 27 Máquinas se obtiene KAGG EVAL VAL = 0.330087
Para 27 Máquinas se obtiene KAGG EVAL TRAIN = 0.262518
Para 29 Máquinas se obtiene KAGG EVAL VAL = 0.328972
Para 29 Máquinas se obtiene KAGG EVAL TRAIN = 0.262024
Para 30 Máquinas se obtiene KAGG EVAL VAL = 0.328946
Para 31 Máquinas se obtiene KAGG EVAL VAL = 0.328942
Para 32 Máquinas se obtiene KAGG EVAL VAL = 0.328493
Para 32 Máquinas se obtiene KAGG EVAL TRAIN = 0.262004
Para 33 Máquinas se obtiene KAGG EVAL TRAIN = 0.261951
Para 35 Máquinas se obtiene KAGG EVAL VAL = 0.328041
Para 35 Máquinas se obtiene KAGG EVAL TRAIN = 0.261687
Para 36 Máquinas se obtiene KAGG EVAL VAL = 0.327956
Para 38 Máquinas se obtiene KAGG EVAL VAL = 0.327935
Para 55 Máquinas se obtiene KAGG EVAL VAL = 0.327548
Para 55 Máquinas se obtiene KAGG EVAL TRAIN = 0.261574
```

Evaluar algoritmo genérico de ensamblado

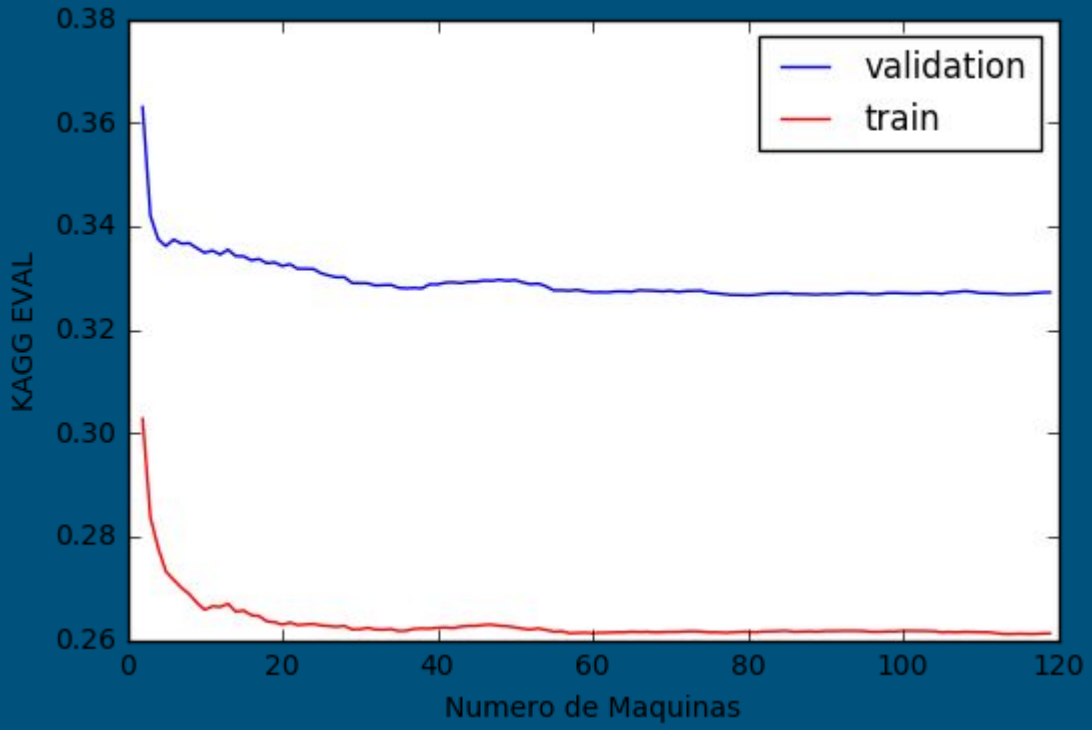

3. Reconocimiento de Imágenes en CIFAR10

Contexto

El dataset CIFAR10 está compuesto por 60.000 imágenes RGB de 32x32 pixeles el cual contiene 10 clases de objetos (6.000 ejemplos por clase). Las clases corresponden a: Gato, Perro, Rana, Caballo, Pájaro, Ciervo, Avión, Automóvil, Camión y Barco.

El conjunto de datos de entrenamiento corresponde a 50.000 imagenes, el de prueba a 10.000 imágenes y el de validación a 10.000 imágenes.

Carga de datos y escalamiento

Se carga los datos de CIFAR10 en 2 matrices de entrenamiento (50.000x32x32), 2 matrices de prueba (10.000x32x32) y 2 matrices de validación (10.000x32x32). Luego se escalan estas matrices dividiendo los valores RGB en 255.

Red Neuronal para clasificación de CIFAR10

Se entrena una red neuronal con 1 capa oculta de 100 neuronas el cual utiliza una función de activación rectificadora (reLU):

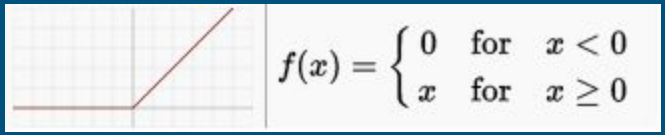

El resultado de esta red neuronal fue el siguiente:

```
 9952/10000 [============================>.] - ETA: 0s
Accuracy de train: 0.819920
Accuracy de validacion: 0.820320
Accuracy de test: 0.820000
```

Red neuronal con Histograma de Color

```
40000/40000 [==============================] - 1s
 9888/10000 [============================>.] - ETA: 0s
Accuracy de train: 0.900000
Accuracy de validacion: 0.900000
Accuracy de test: 0.900000
```

Red neuronal con HOG

```
 9824/10000 [============================>.] - ETA: 0s
Accuracy de train: 0.939097
Accuracy de validacion: 0.923510
Accuracy de test: 0.923050
```

Red neuronal con Histograma de Color y HOG

```
 9536/10000 [============================>..] - ETA: 0s
Accuracy de train: 0.941872
Accuracy de validacion: 0.926120
Accuracy de test: 0.924690
```

SVM no lineal y árbol de clasificación